



**BERGISCHE
UNIVERSITÄT
WUPPERTAL**



**Beitrag zur Approximation der Produktlebensdauer auf Basis
des Degradationsverhaltens unter Zuhilfenahme von
multivariaten Nutzungsmerkmalen am Beispiel der
Aktorenteknologie**

Masterthesis

von

Michael Auer

12. Juli 2019

Fakultät für Maschinenbau und Sicherheitstechnik
Bergische Universität Wuppertal

Lehrstuhl für Zuverlässigkeitstechnik und Risikoanalytik

Prüfer:

Univ.-Prof. Dr.-Ing. Stefan Bracke
M.Sc. Sebastian Sochacki

Tag der Anmeldung: 15.02.2019
Tag der Abgabe: 12.07.2019

Erklärung

Ich erkläre hiermit an Eides statt, dass ich das Thema: "Beitrag zur Approximation der Produktlebensdauer auf Basis des Degradationsverhaltens unter Zuhilfenahme von multivariaten Nutzungsmerkmalen am Beispiel der Aktorentechnologie" selbstständig und ohne fremde Hilfe bearbeitet, nur die angegebenen Quellen und Hilfsmittel benutzt und alle wörtlich oder inhaltlich übernommenen Literaturstellen als solche gekennzeichnet habe.

(Ort, Datum)

(Unterschrift)

Inhaltsverzeichnis

| | | |
|----------|---|-----------|
| 1 | Einleitung | 1 |
| 1.1 | Zielsetzung der Arbeit | 2 |
| 1.2 | Gliederung der Arbeit | 2 |
| 2 | Grundlagen zu Beschreibung von Aktoren | 4 |
| 2.1 | Aktoren mit Formgedächtnislegierungen | 4 |
| 2.2 | Degradation von Formgedächtnislegierungen | 6 |
| 2.3 | Der Versuchsaufbau | 7 |
| 2.4 | Datengrundlage | 8 |
| 3 | Methoden und Stand der Technik | 10 |
| 3.1 | Überblick von dem aktuellen Forschungsstand | 10 |
| 3.2 | Fourier-Analyse | 13 |
| 3.2.1 | Fourier-Transformation | 13 |
| 3.2.2 | Fourierreihe | 16 |
| 3.3 | Regressionsanalyse | 18 |
| 3.4 | Splines | 19 |
| 3.5 | Korrelationsfunktionen | 20 |
| 3.5.1 | Autokorrelation | 20 |
| 3.5.2 | Wiener-Khintchine Theorem | 21 |
| 3.6 | Neuronale Netze | 23 |
| 3.7 | Box-Jenkins Methode | 29 |
| 3.7.1 | Univariate Modelle | 30 |
| 3.7.2 | Multivariate Modelle | 33 |
| 4 | Methodik | 34 |
| 4.1 | Diskussion der Prognosemethoden | 34 |
| 4.2 | Methodik zur Anwendung am Beispiel der Aktorentechnologie | 37 |
| 5 | Auswertung am vorgestellten Datensatz | 38 |
| 5.1 | Autokorrelation | 38 |
| 5.2 | Fourier-Analyse | 42 |
| 5.3 | Neuronale Netze | 51 |
| 5.4 | Ergebnis | 60 |
| 5.4.1 | Zusammenfassung | 60 |
| 5.4.2 | Korrektur des Prüfplatzes | 62 |

| | | |
|-----------|---|-----------|
| 6 | Ausblick | 65 |
| 6.1 | angewandte Methodik | 65 |
| 6.2 | Neuronales Netz zur Ausfallprediktion | 67 |
| 6.3 | Shazam Modell | 68 |
| 7 | Zusammenfassung | 72 |
| I | Abkürzungsverzeichnis | i |
| II | Anhang | ii |
| A | Korrelationsdiagramme | ii |
| B | Ergebnis der linearen Regression | v |
| C | Epochen Verlust Validierung | vii |

Abbildungsverzeichnis

| | | |
|------|---|----|
| 2.1 | Diagramm zur Veranschaulichung der Phasentransformation von FGL in Abhängigkeit der Temperatur und der Dehnung | 5 |
| 2.2 | Skizze Versuchsaufbau des Aktorenprüfplatzes | 7 |
| 2.3 | Ausschnitt aus der Messreihe des Aktorenprüfplatzes | 9 |
| 3.1 | Darstellung von überlagerten Signalen im Zeitbereich | 14 |
| 3.2 | Darstellung des Frequenzspektrums der überlagerten Signale | 15 |
| 3.3 | Beispiel für ein Korrelogramm | 21 |
| 3.4 | Beispiel eines Neuronalen Netzes | 24 |
| 3.5 | Die Aktivierungsfunktionen im Vergleich | 25 |
| 3.6 | Aufbau einer LSTM Zelle | 26 |
| 3.7 | Ein Beispiel zum Overfitting | 28 |
| 5.1 | Autokorrelation der Messreihe des zweiten Datensatzes: Auslenkung von Aktor 1. | 39 |
| 5.2 | Autokorrelation der Messreihe des zweiten Datensatzes: Temperatur. | 40 |
| 5.3 | Autokorrelation der Messreihe des zweiten Datensatzes: Widerstand. | 41 |
| 5.4 | Spektrogramm für die Fouriertransformierte der Aktorendaten. | 42 |
| 5.5 | Spektrogramm für die Fouriertransformierte der Aktorendaten - Versuch ohne Ausfall. | 43 |
| 5.6 | Spektrogramm für die Fouriertransformierte der Aktorendaten - Versuch mit Ausfall. | 44 |
| 5.7 | Fourierspektrum der Temperatur. | 45 |
| 5.8 | Standardabweichungen des Spektrums, zeitlicher Verlauf durch Chunks dargestellt; Datensatz 2. | 47 |
| 5.9 | Aufbau des verwendeten Neuronalen Netzes | 52 |
| 5.10 | Epochenverlust eines Lerndurchlaufes; Validierung mit Testdaten | 55 |
| 5.11 | Gegenüberstellung der realen Testdaten zur Prognose; Ausschnitt von $5 \cdot 10^4$ Daten; Testdaten (blau); Prognosewerte (orange). | 56 |
| 5.12 | Prinzipiskizze des Prüfplatzaufbaus mit Abstandstaster | 62 |
| 5.13 | Ausschnitt aus einem Zeitpunkt zum Ende der Messreihe (Datensatz 2) des Aktorenprüfplatzes | 63 |
| 6.1 | Ablaufdiagramm Ausfallprognose von Motorendaten mit Frequenzdaten | 66 |
| 6.2 | Visualisierte Arbeitsschritte zur Erstellung eines Hash Wertes aus einem Audiosignal | 69 |
| 6.3 | Abgleich eines Audio-Mitschnittes mit der Datenbank | 70 |

| | | |
|-----|--|-----|
| A.1 | Autokorrelation der Messreihe des ersten Datensatzes: Auslenkung von Aktor 1. | ii |
| A.2 | Autokorrelation der Messreihe des ersten Datensatzes: Temperatur. . | iii |
| A.3 | Autokorrelation der Messreihe des ersten Datensatzes: Widerstand. . | iv |
| B.4 | Standardabweichungen des Spektrums, zeitlicher Verlauf durch Chunks dargestellt: Datensatz 1. | v |
| B.5 | Epochen Verlust eines Lerndurchlaufes: Validierung mit Trainingsdaten | vii |

Tabellenverzeichnis

| | | |
|-----|---|------|
| 4.1 | Vergleich der Methoden in Bezug auf Anwendungsmerkmale | 36 |
| 5.1 | Gegenüberstellung der verwendeten Daten für die Fourierreihenapproximation | 48 |
| 5.2 | Ergebnisse der Approximation der Aktorendaten mittels der Fourierreihe | 49 |
| 5.3 | Beschreibung der Layer des Neuronalen Netzes | 51 |
| 5.4 | Ergebnisse des trainierten Neuronalen Netzes trainiert mit Datensatz 1 und den Variablen Spannung, Zeit und Auslenkung. | 54 |
| 5.5 | Ergebnisse des trainierten Neuronalen Netzes trainiert mit Datensatz 2 und den Variablen Spannung, Zeit und Auslenkung | 57 |
| 5.6 | Ergebnisse der Neuronalen Netze (a) trainiert mit Temperatur, Zeit, Spannung, Auslenkung (b) trainiert mit Zeit und Auslenkung | 58 |
| 5.8 | Gegenüberstellung der Mittelwerte der mittleren quadratischen Abweichung von den verschieden gelernten Neuronalen Netzen | 59 |
| 5.9 | Gegenüberstellung der Ergebnisse der Methoden | 61 |
| B.1 | Werte der Regressionsanalyse der Standardabweichung des Aktorenspektrums (Datensatz 1) mit der Formel $y(x) = a \cdot x + b$, sowie dem p-value des einseitigen Wald-Wolfowitz Runs-Test (Wald und Wolfowitz 1940) | vi |
| B.2 | Werte der Regressionsanalyse der Standardabweichung des Aktorenspektrums (Datensatz 2) mit der Formel $y(x) = a \cdot x + b$, sowie dem p-value des einseitigen Wald-Wolfowitz Runs-Test(Wald und Wolfowitz 1940) | viii |

1 Einleitung

In Zeiten der Digitalisierung kommt es zu neuen Herausforderungen für Ingenieure. Die Komplexität von Produkten steigt, die Anforderungen müssen sich anpassen und die Kunden erwarten weiterhin intuitive bedienbare Produkte. Die Zuverlässigkeit-, Risikoanalytik- sowie die Prüf- und Messtechnikbranche muss darauf reagieren und diese Erwartungen erfüllen. Ein neues Berufsbild hat sich zusätzlich in den letzten Jahren entwickelt: Der Data Scientist (Datenwissenschaftler). Dieser Beruf wurde von Davenport und Patil im Harvard Business Review (2012) mit "Sexiest Job of the 21st Century" (Attraktivster Job des 21. Jahrhunderts) betitelt. Bei diesem werden große Datenmengen analysiert und Informationen aus diesen geschöpft. Das Gebiet der Statistik ist von der Grundidee gleich, Rinne bezeichnet diese im *Taschenbuch der Statistik* als "[...] eine systematische Verbindung zwischen Erfahrung (Empirie) und Theorie [...]" (Rinne 2008, S.1). Der Unterschied liegt in der Art und Weise wie die Daten vorliegen; die Datenwissenschaftler beschäftigen sich oftmals mit Datenmengen, die nur mit digitaler Hilfe verarbeitet werden können. Die klassische Statistik hat den Vorteil der Digitalisierung auch erkannt, besitzt aber einen anderen Fokus. Die verschiedenen Disziplinen finden gemeinsame Nenner und Überschneidungen, wenn es um die Methodiken geht.

Die steigenden Produktfunktionalitäten und schnelleren Innovationszyklen benötigen für die Prognose der Lebensdauer von Bauteilen diese Methodiken. Diese Approximation wird komplexer mit steigenden Produktzahlen und zunehmender Anzahl an Merkmalen. Es sind viele Methoden und Modelle zur Bearbeitung dieser Thematik entstanden. Die empirische Frage, die Kinney (1978) dabei in seinem Paper aufwirft:

"Welches Modell soll angewandt werden?"

ist aber bis heute nicht generalisiert beantwortet worden.

1.1 Zielsetzung der Arbeit

Diese Arbeit analysiert verschiedene Methoden zur Zeitreihenanalyse. Mittels multivariater Betrachtung und dem Umgang mit großen Datenmengen werden hier verschiedene Methoden eingeführt und angewendet. Diese werden erörtert und in Hinblick auf die exemplarische Anwendung am Beispiel von Aktoren diskutiert. Für diese Aufgabe stehen Daten aus Dauertests zur Verfügung, die als Zeitserie behandelt werden können. Ein Prüfstand simuliert durch zyklische Belastung die Nutzung im Feld mit entsprechendem zu erwartenden Degradationsverhalten. Ein Teilbereich dieser Arbeit betrachtet die Daten im Frequenzbereich. Hierzu gilt es die Daten im Spektralbereich darzustellen sowie das degradierende Verhalten abzuleiten oder gegebenenfalls zu bestimmen. Weitere statistische Methoden zur Erkennung von Stör- und Einflussgrößen sind zu betrachten und hinsichtlich Materialermüdung zu diskutieren. Darauf aufbauend sind multivariate Ansätze hinsichtlich der Anwendung zu überprüfen. Um die Produktlebensdauer von Aktoren zu betrachten, sollen die Zeitserien entwickelt, Prognosen angefertigt und validiert werden. Durch dieses Vorgehen wird ein Beitrag zur Zeitserienanalyse und Degradationserkennung geschaffen.

Der Ursprung dieser Arbeit liegt in der Zuverlässigkeitstechnik. Ein Anspruch an diese Arbeit ist es, weitere Wissenschaften zu betrachten. Zusätzlich wird versucht, keine Reduktion von Daten vorzunehmen, da diese mit Informationsverlust verbunden sind.

Für die Auswertungen und Plots wird die Programmiersprache Python verwendet (Version: 3.7) sowie die zum aktuellen Zeitpunkt gebräuchlichen Bibliotheken (pandas, matplotlib, scipy, tensorflow o.Ä.).

1.2 Gliederung der Arbeit

Zu Beginn dieser Arbeit werden die Grundlagen vermittelt, die es dem Leser ermöglichen die Problemstellung und die verwendeten Methoden nachzuvollziehen. Bevor konkrete Ansätze vorgestellt werden, werden die verwendete Aktorentechnologie und die Erstellung des Datensatzes anhand des Prüfplatzes (Kapitel 2) erläutert. Mit der Analyse und Definition von Degradation, in Bezug auf die Aktoren, stellt dieses Kapitel die technischen Grundlagen zur exemplarischen Auswertung dar.

Die Beschreibung der Messdaten leitet in die folgende Methodenerklärung (Kapitel 3) über. In diesem Kapitel werden, beginnend mit einem Überblick zum aktuellen

Stand der Technik, Methoden aus Forschung und Industrie zur Zeitserienanalyse vorgestellt.

Die allgemeinen Modelle aus dem Stand der Technik werden in dem Kapitel der Methodik (Kapitel 4) bewertet. Eine Diskussion hinsichtlich der Anwendbarkeit auf die Aktorendaten wird durchgeführt und das weitere Vorgehen für die Auswertung festgelegt.

Im Kapitel 5 werden die vorgestellten Ansätze auf die Aktorendaten angewendet. Am Ende wird das Kapitel durch den Vergleich der Ergebnisse und die Fehlerdiskussion zusammengefasst.

Offene Fragen im Zusammenhang mit erarbeiteten Ergebnissen werden zu Konzepten und Weiterführungen im Ausblick (Kapitel 6). Zusätzlich werden idealisierte Modelle zur Lebensdauerprognose vorgestellt.

Die vollständige Arbeit wird zum Abschluss im Kapitel 7 zusammengefasst und in Hinblick auf die Erreichung der Zielstellung diskutiert.

2 Grundlagen zu Beschreibung von Aktoren

In diesem Kapitel werden die Herkunft der Daten, der Versuchsaufbau sowie die Art der erfassten Daten erklärt. Der technische Hintergrund, der aktuelle Stand der Formgedächtnislegierung-Aktorentechnologie und eine allgemeine Definition der Degradation leiten in das Kapitel ein. Zusätzlich sollen die notwendigen Informationen über die Realdaten vermittelt werden.

2.1 Aktoren mit Formgedächtnislegierungen

Es gibt unterschiedliche physikalische Methoden, um Aktoren umzusetzen. Beispiel für selbige sind Bimetall-, Zylinder- oder elektrochemische Aktoren. In dieser Arbeit werden Daten von Messungen an Aktoren mit einer Formgedächtnislegierung (FGL) verwendet. Bei diesen Legierungen kann die Art der Anregung unterschieden werden (magnetisch, thermisch etc.). Die, in dieser Arbeit verwendeten, besitzen die physikalische Eigenschaft der thermischen Erregbarkeit. Sie werden im Weiteren nur als Formgedächtnislegierung bezeichnet. Auf den Zusatz der Thermik wird verzichtet.

Die grundlegende Eigenschaft einer Formgedächtnislegierung ist nach Janocha (2010) die reversible Umwandlung des martensitischen in den austenitischen Zustand eines Metalls und umgekehrt. Je nach Temperatur oder mechanisch zugeführter Spannung werden diese zwei unterschiedlichen Kristallstrukturen eingenommen. Bei thermisch erregten FGL wird unterschieden zwischen folgenden Verhaltensweisen (Janocha 2010):

1. Einwegeffekt
2. Zweiwegeffekt
3. Pseudoelastizität

Die verwendeten Legierungen verhalten sich entsprechend des Einwegeffekts. Wie sich dieser Effekt verhält, ist in Abbildung 2.1 skizziert. Die Phasenumwandlung

findet temperaturinduziert bei der Abkühlung (A_s) oder der Erhitzung (A_f) statt. Durch mechanische Spannung lässt sich das martensitische Kristallgitter deformieren (1-3), woraufhin das Metall nach Entlastung im verformten Zustand verbleibt (4). In Folge von Temperaturerhöhungen ändert sich die martensitische Kristallstruktur zur austenitischen. Formgedächtnislegierungen nehmen während der Umwandlung die ursprünglich eingeprägte Form des austenitischen Kristallgitters an (5-6). Anschließend wird das Material wieder auf Ausgangstemperatur abgekühlt (1) und es stellt sich die martensitische Kristallstruktur ein, dabei findet keine zusätzliche äußerliche Verformung statt.

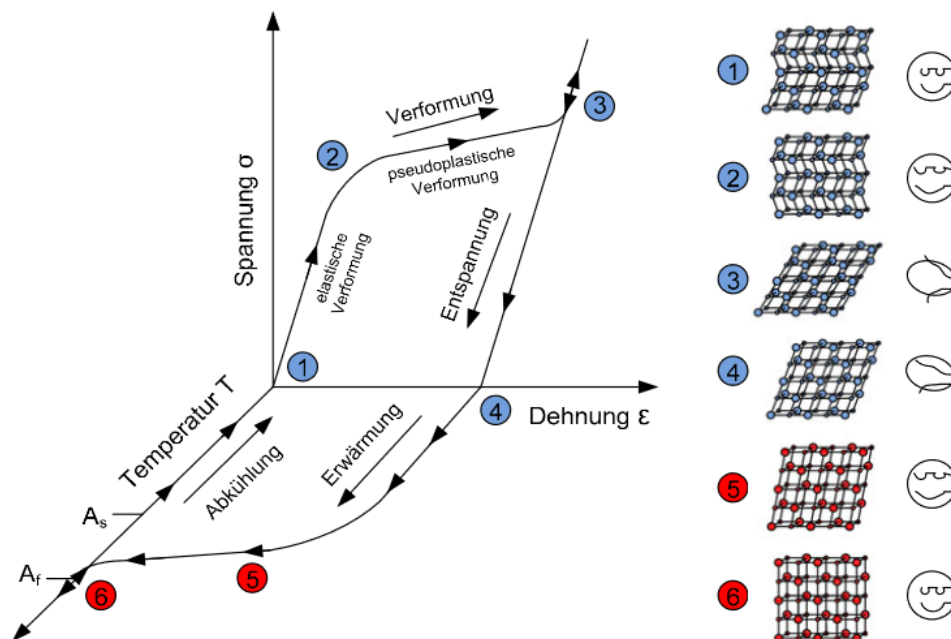


Abbildung 2.1: Diagramm zur Veranschaulichung der Phasentransformation von FGL in Abhängigkeit der Temperatur und der Dehnung; Einwegeffekt (Langbein und Czechowicz 2013)

Zusammengefasst lässt sich festhalten, dass Formgedächtnislegierungen mit Einwegeffekt eine Formänderung der martensitischen Kristallstruktur durch Temperaturänderung reversieren können.

Anwendung finden diese Metalle in der Technik zum Beispiel bei Schrumpfhülsen (Langbein und Czechowicz 2013). Auch in den Konsumgüterbereich haben Formgedächtnislegierungen Einzug gehalten. Wu und Schetky (2000) beschreiben Anwendungen bei Brillen, Drähten von Büstenhaltern oder Antennen. Diese Produkte profitieren von der Flexibilität und der Eigenschaft die Form zu erhalten beziehungsweise wiederherzustellen.

2.2 Degradation von Formgedächtnislegierungen

Degradation beschreibt den Verlust von Materialeigenschaften an einem Bauteil, die sogenannte Materialermüdung. Die Lebensdauer eines Bauteils wird, bei vorgesehener Anwendung, durch diese bestimmt.

Nach Humbeeck (1991) existieren bei Formgedächtnislegierungen drei verschiedene Arten der Materialermüdung und stellen somit Fehlermodi für die Bauteile dar:

1. Der Bruch des Materials aufgrund von zyklischer Belastung bei konstanter Temperatur. Dabei wird unterschieden zwischen der Belastung oberhalb von A_f und Schäden durch fehlerhafte Kristallstruktur.
2. Die Änderungen in Bezug auf physikalische, mechanische oder funktionelle Eigenschaften. Zum Beispiel treten veränderte Transformationstemperaturen bedingt durch des Degradationsverhalten auf.
3. Die Abnahme des Formgedächtnis-Effekts durch zyklische Stress-, Belastungs- oder Temperaturänderungen.

Der erste Fehlermodus erhielt bisher die größte Aufmerksamkeit in der Literatur (vgl. Humbeeck 1991). Buehler und Wang (1968) beschreiben Dauerbelastungstest von Nickel-Titan Legierungen, die ohne Schaden mehr als 10^7 Belastungszyklen durchliefen. Die Beschaffenheit der Legierung und die Temperatur der Testumgebung haben bei der Rissentwicklungen einen nachweisbaren Einfluss (Wilkes, Liaw und Wilkes 2000). Fehlermodi von metallischen Brüchen wie Rissfortschritt, Dauer-schwingbruch o.Ä. sind weitestgehend erforscht und durch Konzepte wie das Gesetz zum Bruchwachstum nach Paris (1961), Miner (1945) oder Coffin-Manson (Manson 1953 und Coffin 1953) beschrieben. Das Ermüdungsverhalten von FGL-spezifischen Eigenschaften (Fehlermodus 2 und 3) ist nicht allgemein beschrieben und benötigt weitere Forschung (vgl. Wilkes, Liaw und Wilkes 2000).

2.3 Der Versuchsaufbau

Zur Messung der Lebensdauer von Formgedächtnislegierungen wird eine Last an einem Draht aus einer FGL angebracht und mit einem Bowdenzug angehoben. Ein vollständiger Prüfplatz aller Aktuatoren wurde bereits in dem Paper *Zuverlässigkeitstechnik bei Formgedächtnisaktoren: Entwicklung von Prüfstandstechnik und Erprobungsprogramm*. (Heß und Bracke 2018) erläutert. Hier wird der modifizierte Prüfplatz nach Hess und Bracke 2019 vorgestellt. Die Prüfvorrichtung basiert auf der Auslenkung des Drahtes aufgrund des Erhitzens durch anliegende Spannung und dem resultierenden Strom. Bei diesem Prüfplatz werden bis zu sechs Aktoren gleichzeitig geprüft. Die Prinzipskizze des Versuchsaufbaus für einen Aktor ist in Abbildung 2.2 zu sehen.




Abbildung 2.2: Skizze Versuchsaufbau des Aktorenprüfplatzes (Hess und Bracke 2019; modifiziert).

Eine Vorrichtung besteht aus den folgenden Elementen:

| | | |
|--------------------|----------------------|------------------------|
| [1] Stopper | [4] Bewegbares Lager | [7] Fixiertes Lager |
| [2] Abstandssensor | [5] Feder | [8] Verbindungselement |
| [3] Stromquelle | [6] FGL Draht | [9] Platine |

Eine definierte Anzahl an FGL-Drahtpaaren [6] ist zwischen dem beweglichen Lager [4] und dem fest fixierten Lager [7] gespannt. Diese werden durch einen Pin zentriert und auf einer Leiterplatte [9] fixiert. Die Drähte werden mit den Verbindungselementen [8] zusammengefasst. Der Prüfvorgang wird über das Anlegen von Spannung [3]

eingeleitet. Durch die Erhitzung des FGL Drahtes formt sich dieser in seine zuvor eingeprägte Struktur zurück. Die daraus resultierende Kraft zieht das bewegliche Lager entgegen der Federrückstellkraft [5] nach unten. Der Abstandsensor [2] nimmt über eine Lasermessung die durchgeführte Auslenkung des Lagers wahr und speichert diese Daten. Nachdem die Spannung entfernt wird, kühlt sich der Draht ab und die Feder drückt das Lager zurück in die Ursprungsposition. Der Stopper [1] stellt diese Position als $z=0$ dar. Zusätzlich misst ein Temperatursensor die Umgebungstemperatur in der Mitte des gesamten Prüfaufbaus aller Aktoren (Hess und Bracke 2019).

2.4 Datengrundlage

Es werden zwei Datensätze verwendet und verglichen. Der zweite Datensatz enthält Ausfälle der Aktoren. Die Drähte sind zu einem Zeitpunkt t_a gerissen. Die Daten sind wie folgt aufgebaut:

- Ohne Ausfälle (Datensatz 1); ca. 192.452 Messzyklen, 5 Aktoren versetzt gemessen.
- Mit Ausfällen (Datensatz 2); ca. 139.900 Messzyklen, 6 Aktoren versetzt gemessen.

Die Daten liegen als CSV-Datei vor. Die Messung wurde fortlaufend durchgeführt, wobei folgende Parameter aufgezeichnet werden.

- Zeit seit Beginn der Messung [s]
- Auslenkung [mm]
- Spannung [V]
- Stromstärke [A]
- Temperatur [°C]

Die beiden Variablen Spannung und Stromstärke können mittels des Ohmschen Gesetzes $R = \frac{U}{I}$ durch den Widerstand [Ω] ausgedrückt werden. Die Temperatur wird

aufgezeichnet, wird aber nicht aktiv im Versuch geändert. Der Temperatureinfluss bezieht sich auf Schwankungen in der Testkammer.

Ein Ausschnitt einer Messreihe zum Ermüdungsverhalten von FGL ist in Abbildung 2.3 zu sehen. Dabei ist der Zyklus des Prüfprozesses zu erkennen. Nach dem Anlegen der Spannung lenkt der Draht aus und zieht das Lager entgegen der Feder. Die Auslenkung findet, wie in Kapitel 2.3 beschrieben wird, nach unten statt und erzielt einen negativen Wert aufgrund des definierten Koordinatensystems. Zur Darstellung und weiteren Berechnung wird daher der Absolutwert der Auslenkung verwendet. Für die Rückstellung des Drahtes muss eine spannungsfreie Zeit eingelegt werden. Das Entspannen dauert länger als das Anspannen.




Abbildung 2.3: Ausschnitt aus der Messreihe (Datensatz 2) des Aktorenprüfplatzes

Die Temperatur ändert sich langsam, wobei die spontanen Temperaturschwankungen des Messergebnisses auf das Messverfahren zurückzuführen sind. Diese wird nachdem alle Aktoren gemessen wurden, erneut gemessen. Das Verhalten, dass die Daten zwischen zwei Punkten springen, ist mit dem gegebenen Wissensstand zum Aufbau des Prüfstandes nicht zu erklären.

3 Methoden und Stand der Technik

In diesem Kapitel werden die in dieser Arbeit verwendeten Methoden zur Analyse von Zeitreihen vorgestellt. Aufgrund des umfangreichen Themengebiets wird dieses Kapitel mit der Zusammenfassung einer Recherche begonnen, die dem Leser einen Überblick verschafft. Daraufhin werden ausgewählte Methoden vorgestellt. Es sollen die fachlichen Informationen zum Verständnis der Methoden vermittelt werden. Eine Bewertung der Methoden wird in dem nachfolgenden Kapitel 4 durchgeführt.

3.1 Überblick von dem aktuellen Forschungsstand

Diese Arbeit beschäftigt sich primär mit der Auswertung von Zeitreihen zur Produktlebensdaueranalyse. Eine Definition von Zeitreihen lautet nach der Monographie *Einführung in die moderne Zeitreihenanalyse* folgendermaßen: "Unter einer Zeitreihe wollen wir zunächst eine Menge von Beobachtungswerten quantitativ ausgeprägter Merkmale verstehen, die nach der Zeit geordnet sind. Dabei soll der Zeitparameter generell als diskret unterstellt werden" (Gebhard und Jürgen 2006, S. 1). Der Anwendungszweck der Zeitreihenanalyse ist beschrieben wie folgt: "Zeitreihenanalysen dienen dazu, die in einer Variablen enthaltenen Regularitäten aufzufinden und daraus 'Gesetze' abzuleiten, und/oder alle in einer Zeitreihe enthaltenen Informationen zu erfassen, damit künftige Entwicklungen zuverlässiger vorhergesagt werden können" (Gebhard und Jürgen 2006, S. 3).

In dieser Betrachtung zeigt sich der Zusammenhang zu den Aktorendaten. Diese sind nach der Zeit geordnete Beobachtungswerte quantitativ ausgeprägter Merkmale. Auch die Aussage über die Zeitreihenanalyse korrespondiert zur Zielsetzung dieser Arbeit überein. Die enthaltenen Regularitäten sollen aufgefunden werden und daraus Gesetzmäßigkeiten in Zusammenhang mit der Degradation abgeleitet werden.

Die Literatur bietet zu dem Thema Zeitreihenanalyse in Zusammenhang mit Statistik viele Grundlagen. Dieses Forschungsfeld besitzt eine lange Geschichte, wie Brandt und Williams in ihrer Einführung von *Multiple time series models* beschreiben. Bereits vor 220 Jahren erschienen Publikationen, die im sozialwissenschaftlichen

Kontext Zeitserien ausgewertet. Beispielsweise wurden historische Ereignisse, wie der Spanische Krieg im Jahre 1730, analysiert. Inzwischen haben die Zeitserienanalysen auch Einzug in weitere Wissenschaftsdisziplinen gehalten. Die Wirtschaft verwendet Modelle um die Wirtschaftlichkeit von Unternehmen zu bewerten (Jürgen 2015). Die angewandten Naturwissenschaften bewerten Lebensdauern von Produkten unter Berücksichtigung der zeitlichen Veränderung ihres Verhaltens (Chen und Zheng 2005).

Gegenwärtige Methoden der Zeitreihenanalyse sind analytische Prozesse wie das Moving-Average Modell, das Autoregressive Model oder die Regression. 1978 wurde von Kinney ein Review über den Vergleich von autoregressive integrated moving average Modellen (autoregressive gleitende Durchschnitts-Modellen; ARIMA) und der Regressionsanalytik veröffentlicht. Mittels verschiedener Testverfahren kam er zu dem Ergebnis, dass die besten Verfahren zur Prognose viele Informationen benötigen, hierfür aber auch viel Rechenzeit aufgewendet werden muss. Bei einfachen Modellen ist die Regression vorzuziehen. Durch die Rechenzeiterparnis ist diese wirtschaftlicher, da weniger Daten aufgezeichnet werden müssen und die Berechnung effizienter ist. Das ARIMA Modell findet primär in den Wirtschaftswissenschaften Verwendung und wird auf wirtschaftliche Kenngrößen (Enders 2015), sowie in den Sozialwissenschaften für die Berechnung von epidemiologischen Verläufen angewandt. Eines der einflussreichsten Werke nach Gebhard und Jürgen (2006) zur Zeitreihenanalyse ist die Monographie *Time series analysis: forecasting and control* von Box u. a., auf dem das Box-Jenkins Modell basiert.

In den Naturwissenschaften lassen sich im Zusammenhang mit Zeitreihen weitere Problemstellungen und Lösungsansätze finden. Die Physik und Elektrotechnik beschäftigen sich unter anderem mit periodischen Funktionen. Die Ausgangslage der Daten ist hierbei eine andere. Diese liegen meist als Signale vor und nicht als diskrete Zeitwerte. Diese Funktionen können aber durch Einsetzen eines periodischen Zeitsignales in diskrete Werte umgewandelt werden. Daher können diese Funktionen nach der Definition von Gebhard und Jürgen auch als Zeitreihen betrachtet werden. Ein Ansatz dabei ist die Transformation der zeitabhängigen Funktionen in den Frequenzbereich. Mit diesem Vorgehen können Eigenschaften der Funktion in Bezug auf ihr Spektrum dargestellt werden (Gasquet, Witomski und Ryan 1999). Oftmals können diese Methoden auf "klassische" Zeitreihen nicht angewandt werden, da keine Periodizität vorliegt. Umfangreiche Veröffentlichungen über Zeitreihen wie z.B. *Time series analysis: with applications in R* (Cryer und Chan 2011) oder *Time series analysis* (Hamilton 1994) enthalten einen kurzen Ausblick in diese Thematik. Für Literatur zu diesen Fachgebiet sind Werke aus der Physik oder Signalverarbeitung zum Transfer besser geeignet (z.B.: *Mathematische Methoden in der Physik* (Lang und Pucker 2016), *The Spectral analysis of time series* (Koopmans 1974)

oder *Einführung in die Systemtheorie: Signale und Systeme in der Elektrotechnik und Informationstechnik* (Girod, Rabenstein und Stenger 2003).

Zuletzt ist eine weitere Disziplin in dem Kontext zu erwähnen. Aufgrund der exponentiell gestiegenen Möglichkeit Daten aufzunehmen und zu verarbeiten, steigt die Bedeutsamkeit der Informatik in Zusammenhang mit der Datenauswertung weiter an. Gleichwohl ist auch das Interesse an Methoden gestiegen, mit denen diese Daten verarbeitet werden können. Auch die Zeitreihenanalytik profitiert von diesem Phänomen. Die Firma Facebook Inc. veröffentlichte zum Beispiel 2017 ein eigenes Tool zur Zeitreihenprognose für die Programmiersprachen Python und R (Facebook Inc. 2017). Mit dem Namen "Prophet" dient es der Marktanalyse von Facebook und basiert auf zwei modularen Modellen, einem linearen und einem mit einer Sättigung (Taylor und Letham 2017). Dies zeigt das Interesse an der Analyse von Zeitreihen mit großen Datenmengen. Eine zweite Methode aus den Datenwissenschaften ist das Neuronale Netz, welches das Verhalten des menschlichen Gehirns auf rudimentäre Weise nachbildet und selbstständig Muster und Funktionen erkennen soll (Grossberg 1989). Diese Eigenschaft führt dazu, dass es in vielen Wissenschaften verwendet werden kann. Das aktuell bekannteste Beispiel hierfür ist der Google-Suchmaschinen Algorithmus, der unter Anderem auf neuronalen Netzen basiert. Das Verfahren kann auch für die Prognose von Zeitreihen verwendet werden, sowie den Einfluss von multivariaten Nutzungsmerkmalen untersuchen.

Aufgrund der Komplexität dieses Themengebietes wird für weitere Methoden auf die angegebene Literatur verwiesen. In dem folgenden Kapitel werden ausgewählte Methoden und Konzepte vorgestellt, die in der weiteren Arbeit diskutiert und verwendet werden.

3.2 Fourier-Analyse

Die Fourier- oder Spektral-Analyse wandelt die vorliegenden diskreten Daten um, sodass diese im Frequenzbereich betrachtet werden können. Darum wird die Fouriertransformation vorgestellt sowie eine mathematische Methode um Funktionen im Frequenzbereich zu entwickeln: die Fourierreihe.

3.2.1 Fourier-Transformation

Die Fouriertransformation ist eine Integraltransformation, die eine Funktion im Zeitbereich $f(t)$ in den Frequenzbereich $F(\omega)$ transformiert und sich nach *Mathematik für Ingenieure und Naturwissenschaft* (Papula 2015) wie folgt definieren lässt:

$$F(\omega) = \int_{-\infty}^{\infty} f(t) \cdot e^{-j\omega t} dt \quad (3.1)$$

Oder alternativ in gekürzter Schreibweise mit dem Fourier-Transformationsfunktional \mathcal{F} :

$$F(\omega) = \mathcal{F}\{f(t)\}$$

Bei der Überlagerung mehrerer Schwingungen wird der Vorteil der Fouriertransformation sichtbar. In der folgenden Abbildung 3.1 werden drei verschiedene Schwingungen mit einem weißen Rauschen überlagert worden. Zur diskreten Erstellung der Werte wird eine Abtastrate der Signale simuliert, diese stellt einen Messvorgang dar. Die Differenzierung der Funktionen ist im Zeitbereich nicht mehr eindeutig zu treffen. Eine eingebaute exponentielle Degradation kann in dem Graph erkannt werden, da die Amplitude des Gesamtsignals zum Ende hin abfällt.




Abbildung 3.1: Darstellung von überlagerten Signalen im Zeitbereich

Für dieses Signal wird die Fouriertransformation angewandt. Zur Identifikation der Frequenzen wird das komplexe Ergebnis als Betragswert dargestellt. Die Frequenz wird aufgrund der Abtastrate ermittelt, die für die Erstellung des Beispiels verwendet wurde. Die Spektrogramme werden mittels der Betragsbildung dargestellt, in weiteren Berechnungen dieser Arbeit werden die komplexen Werte verwendet.

Die Fouriertransformation liefert im Frequenzbereich Informationen, die die Auswertung vereinfachen. Das Frequenzspektrum (Abbildung 3.2) zeigt die Frequenzen der vorliegenden Schwingungen. Zusätzlich ist das weiße Rauschen anhand der Anhebung der Daten im Fourierraum zu erkennen. Ohne dass weitere Informationen über das ursprüngliche Signal vorliegen, lassen sich die drei vorgegebene Grundschwingungen eindeutig identifizieren. Das Spektrum der Amplituden besitzt Peaks bei 7 Hz, 12 Hz und 50 Hz, wobei die Schwingung bei 12 Hz am stärksten ausgeprägt ist. Das Grundrauschen ist identifizierbar als Störfrequenzen in dem gesamten Spektrum.




Abbildung 3.2: Darstellung des Frequenzspektrums der überlagerten Signale

Im Laufe der Zeit haben Forscher verschiedene Algorithmen zur schnelleren Berechnung der Transformation (Fast-Fourier-Transform (FFT)) gefunden. Darunter fallen:

- Cooley-Tukey
- Prime-factor FFT
- Bruun's FFT

In dieser Arbeit wird die FFT Funktion der numpy Bibliothek für die Berechnung der Fouriertransformation verwendet (*numpy, FFT Dokumentation* 2019). Der Algorithmus ist der Cooley-Tukey Algorithmus (vgl. Cooley und Tukey 1965). Diese muss nach der Berechnung normalisiert werden, die Rechenschritte sind nach dem Verfahren gewählt worden.

3.2.2 Fourierreihe

Periodische Funktionen können mittels der Fourierreihe entwickelt werden. Diese wird, mit der Periode T , wie folgt definiert (Marks 2009):

$$x(t) = \sum_{n=-\infty}^{\infty} c_n \cdot e^{\frac{j2\pi nt}{T}} \quad (3.2)$$

Die Fourierkoeffizienten c_n sind beschrieben durch

$$c_n = \frac{1}{T} \int_T x(t) e^{\frac{-j2\pi nt}{T}} dt$$

mit der Integration über einen beliebigen Einzelraum. Es wird mit einem beliebigen τ definiert:

$$\int_T := \int_{t=\tau}^{\tau+T}$$

Hierzu müssen folgende Eigenschaften erfüllt sein:

- "Das Periodenintervall lässt sich in endlich viele Teilintervalle zerlegen, in denen $f(x)$ stetig und monoton ist"
- "Besitzt die Funktion $f(x)$ im Periodenintervall Unstetigkeitsstellen (es kommen nur Sprungunstetigkeiten mit endlichen Sprüngen infrage), so existiert in ihnen sowohl der links- als auch der rechtsseitige Grenzwert"
- "In den Sprungstellen der Funktion $f(x)$ liefert die Fourier-Reihe von $f(x)$ das arithmetische Mittel aus dem links- und rechtsseitigen Grenzwert der Funktion"

(entnommen aus *Mathematische Formelsammlung* (Papula 2014))

Durch Umformung mittels der Umrechnung von der trigonometrischen Form auf die Exponentialform $(\cos \phi + j \cdot \sin \phi) = e^{j\phi}$ (Papula 2014) ergeben sich die folgenden diskreten Formeln zur Berechnung der Fourierreihe:

$$y(t) = \frac{a_0}{2} + \sum_{n=1}^{\infty} [a_n \cdot \cos(n\omega_0 t) + b_n \cdot \sin(n\omega_0 t)] \quad (3.3)$$

Sowie die Fourierkoeffizienten

$$a_0 = \frac{2}{T} \int_{(T)} y(t) dt \quad (3.4)$$

$$a_n = \frac{2}{T} \int_{(T)} y(t) \cdot \cos(n\omega_0 t) dt \quad (3.5)$$

$$b_n = \frac{2}{T} \int_{(T)} y(t) \cdot \sin(n\omega_0 t) dt \quad (3.6)$$

wobei ω_0 die Kreisfrequenz der Grundschiwingung darstellt und $n \in \mathbb{N}^*$ gilt (vgl. Papula 2014).

Mithilfe der Fourierreihe ist es möglich, die Funktion $f(x)$ mittels der Fourierkoeffizient als eine Summe von Sinus- und Kosinusschwingungen darzustellen. Mathematisch gesehen ist die Fouriertransformation eine Fourierreihe bei der die Summe gegen Unendlich entwickelt wird. Der Vorteil der Reihedarstellung ist, dass diskret die einzelnen Koeffizienten berechnet werden können und somit die Funktion $F(\omega)$ darstellt. Die Reihe kann damit für Vorhersagen verwendet werden.

3.3 Regressionsanalyse

Die Regressionsanalyse besteht aus unterschiedlichen statistischen Analyseverfahren. Urban und Mayerl (2018) legen das Ziel dieser Verfahren fest: "[...] in welcher Weise die Veränderungen in den Werten einer bestimmten Variablen zu Veränderungen in den Werten einer anderen Variable führen". Dieses Themengebiet umfasst verschiedene Methoden wie:

- lineare Regression
- nicht-lineare Regression
- Analyse mit Zeitkomponenten (z.B. Überlebensanalysen)
- multivariate Modelle
- nicht-parametrische Regression

Bekannte Methoden wie die ordinary least square (gewöhnliche kleinste Quadrate, OLS) Regressionsanalyse, deren einfachste Version mit zwei Variablen die lineare Regression darstellt, werden angewandt, um Zusammenhänge zwischen Variablen festzustellen. Für die Degradationsanalyse anhand einzelner Daten mit multivariaten Einflüssen sind zur Berechnung der Kausalität der Variablen die Methoden der linearen-, nicht-linearen- und der multivariaten Regression geeignet. Die Überlebensanalyse ist für Flottenbetrachtungen ein passendes Verfahren und kann auch für Zeitreihenanalyse angewandt werden.

Besteht die Annahme einer Linearität des Modells, das die Datenpunkte beschreibt, so kann die folgende Gleichung mit der Funktion der kleinsten Quadrate angepasst werden (vgl. Urban und Mayerl 2018:

$$Y_i = \alpha + \beta \cdot X_i + \varepsilon_i \quad (3.7)$$

ε_i stellt ein zufällige Fehler dar. Dieses Modell wird erweitert mit k Einflussvariablen zur linearen Mehrfachregression.

$$Y_i = \beta_1 \cdot X_{i1} + \beta_2 \cdot X_{i2} + \dots + \beta_k \cdot X_{ik} + \mu_i = x_t^T \beta + \varepsilon_t \quad \text{wobei} \quad t \in \mathbb{N} \quad (3.8)$$

Mit der multivariaten Regression ist es möglich, die Parameterabhängigkeiten mit einer Varianz-Kovarianz-Matrix zu berechnen. Diese Matrix stellt die Abhängigkeiten der Variablen und zu sich selbst dar. Mit dem Erwartungswert E und der Transponierten T definiert sich die Varianz-Kovarianz-Matrix wie folgt:

$$Cov(\varepsilon) = E(\varepsilon\varepsilon^T) = \begin{pmatrix} Var(\varepsilon_1) & Cov(\varepsilon_1, \varepsilon_2) & \dots & Cov(\varepsilon_1, \varepsilon_T) \\ Cov(\varepsilon_2, \varepsilon_1) & Var(\varepsilon_2) & \dots & Cov(\varepsilon_2, \varepsilon_T) \\ \vdots & \vdots & \ddots & \vdots \\ Cov(\varepsilon_T, \varepsilon_1) & Cov(\varepsilon_T, \varepsilon_2) & \dots & Var(\varepsilon_T) \end{pmatrix} \quad (3.9)$$

Diese Matrix besitzt die Eigenschaft der Symmetrie zur Hauptdiagonalen, da $Cov(\varepsilon_i, \varepsilon_j) = Cov(\varepsilon_j, \varepsilon_i)$ gilt. Die Regressionsanalyse stellt die Kausalitäten der Variablen auf und ist für Zeitserien ein qualitatives Prognosetool. Die angepassten Funktionen können zur Approximation verwendet werden, aber für eine genaue Vorhersage ist diese Methode nicht geeignet. Modelle, die über Linearität hinausgehen, werden mit der nichtlinearen Regression angefitet. Je nach Modell ist der Fehler nicht normalverteilt. Somit kann das Verfahren der kleinsten Quadrate nicht angewandt werden und das Maximum Likelihood Verfahren wird verwendet. Die Komplexität der Parameterschätzung nimmt zu (vgl. Ritz 2009).

3.4 Splines

Während die Regression eine bestimmte Modell-Funktion an die Datenpunkte anfitet, sind Splines polynomielle Funktionen, die zwischen ausgewählten Stützpunkten berechnet werden. Splines können als polynomielle Interpolation betrachtet werden. Der Vorteil von Splines gegenüber der Regression ist, dass verschiedene Abschnitte der Daten einzeln berechnet werden und eine jeweilige Funktion erhalten wird. Die Regression kann dies durch Zensieren der Daten erreichen, nimmt aber für jeden Bereich dieselbe Funktion an. Für Zeitserien bedeutet dies, dass die Verhalten zwischen fixierten Stützpunkten ermittelt werden können. Die Polynome können anschließend zur Bestimmung des Degradationsverhaltens verwendet werden.

Die Berechnung von Splines ist ein umfangreiches Themengebiet. Je nach Grad des Polynoms benötigt es unterschiedliche Ansätze. An dieser Stelle wird auf weiterführende Literatur wie Kunoth u. a. 2018 oder Engeln-Müllges und Uhlig 1996 verwiesen. Angewendete Ansätze werden gegebenenfalls vorher eingeführt.

3.5 Korrelationsfunktionen

Die Korrelation beschreibt Zusammenhänge zwischen Variablen. Diese können zum Beispiel Merkmale oder Ereignisse sein. In diesem Unterkapitel wird eine Sonderform der Korrelation, die Autokorrelation, mit zwei unterschiedlichen Berechnungsmethoden eingeführt

3.5.1 Autokorrelation

Unter Autokorrelation wird die Korrelation einer Funktion mit sich selbst, in Bezug auf zeitliche Verschiebung, verstanden. Nach Jürgen(2015) ist die Autokorrelationsfunktion wie folgt definiert:

$$\hat{\rho}(\tau) := \frac{\hat{\gamma}(\tau)}{\hat{\gamma}(0)} = \frac{\sum_{t=1}^{n-\tau} (y_t - \bar{y})(y_{t+\tau} - \bar{y})}{\sum_{t=1}^n (y_t - \bar{y})^2} \quad (3.10)$$

Es wird die Funktion $y(\gamma)$ mit sich selbst verrechnet und im Zeitbereich verschoben. Die Abstände zum jeweiligen Messpunkt werden *Lags* genannt. Eine Visualisierung der Lags zur Autokorrelationsfunktion ist möglich mittels eines Korrelogramms. Die Funktion besitzt am Anfang den Wert 1, da die Varianz im Zähler gleich der der Varianz der Funktion ist. Je kleiner die Autokorrelationsfunktion wird, desto geringer ist die Ähnlichkeit der Funktion mit ihrem Anfangswert. Bei Nullwerten wird davon ausgegangen, dass die Funktion nicht korreliert und das Verhalten einen unkorrelierenden Charakter besitzt. In der Theorie können Autokorrelationsfunktionen auch Rauschfilter darstellen, da Rauschen per Definition nicht korrelieren kann. Für stochastische Prozesse wird die, auf den Bereich von -1 bis 1, normierte Autokorrelation verwendet. Eine beispielhafte Darstellung eines Korrelogramms ist in der folgenden Abbildung dargestellt.




Abbildung 3.3: Korrelogramm - Gegenüberstellung Autokorrelationsfunktion (ACF) und Lag (Jürgen 2015)

3.5.2 Wiener-Khintchine Theorem

Das Wiener-Khintchine¹ Theorem besagt, dass die spektrale Leistungsdichte S eines stationären Prozesses die Fourier-Transformation der Autokorrelationsfunktion ist (Khintchine 1934). Es gilt nach Cohen (Cohen 1998) eine fourier-transformierte Funktion $\mathcal{F}\{f(t)\}$ definiert als

$$F(\omega) = \int_{-\infty}^{\infty} f(t) \cdot e^{-j\omega t} dt \quad (3.11)$$

Für die Inverse gilt demnach:

$$f(t) = \int_{-\infty}^{\infty} F(\omega) \cdot e^{j\omega t} d\omega \quad (3.12)$$

Die spektrale Leistungsdichte S und somit die Fourier-Transformierte der Autokorrelationsfunktion wird auf Basis von Khintchine (1934) ausgedrückt durch:

$$S(\omega) = |F(\omega)|^2 = \int_{-\infty}^{\infty} R(t) e^{-j\omega \tau} dt \quad (3.13)$$

¹ Khintchine wurde aus dem russischen Namen Хинчин übersetzt.
Alternative Schreibweisen: Khinchin, Chintschin, Chinčin

Wobei $R(\tau)$ die deterministische Autokorrelationsfunktion ist:

$$R(\tau) = \int_{-\infty}^{\infty} f^*(t)f(t + \tau)dt \quad (3.14)$$

Durch diese Eigenschaft der Fourier-Transformierten ist es möglich, effizient die Autokorrelation oder Korrelation von Funktionen zu bestimmen. Hierfür muss abschließend die Inverse der spektralen Leistungsdichte berechnet werden. Als Ergebnis kann ein Korrelogramm wie in Abbildung 3.3 erstellt werden. Die Interpretation hierbei ist identisch. Nach *Computer simulation of thermal conductivity in vulcanized polyisoprene at variable strain and temperature* (Engelmann, Meyer und Hentschke 2017) kann die Autokorrelationsfunktion auch diskret dargestellt werden mit der Formel

$$\langle J_\alpha(t)J_\beta(0) \rangle = \langle J_\alpha(k\Delta t)J_\beta(0) \rangle = \frac{1}{n-k} \sum_{i=0}^{n-k} J_\alpha((i+k)\Delta t)J_\beta(i\Delta t) \quad (3.15)$$

Nach Engelmann, Meyer und Hentschke (2017) wird die Komplexität mit dem Wiener-Khintchine Theorem, im Vergleich zur diskreten Lösung, von quadratischer auf lineare Komplexität reduziert und somit auch die Rechenzeit. Für große Datenmengen ist das Theorem besser geeignet, da dort die Rechenleistung für die Wirtschaftlichkeit und Effektivität der Methode einen bedeutsameren Einfluss besitzt. Ein Problem, das bei der Berechnung der Autokorrelation mit großen Datenmengen auftritt, ist die Ungenauigkeit, die mit fortschreitender Berechnung auftritt. Am Ende jeder Autokorrelationsfunktion ist ein rauschähnlicher Zustand zu sehen, der sich aus der endlichen Datenmenge ergibt, die mit der Gesamtfunktion verglichen wird.

Für die multivariate Anwendung wird das Theorem zur Berechnung der Kreuzkorrelationen verwendet. Dieses stellt die Korrelationseinflüsse von zwei Variablen zueinander dar. Nach Koopmans (1974) wird das Wiener-Khintchine Theorem durch folgende Formel angewandt:

$$C_{j,k}(\tau) = \frac{1}{2T} \int_{-T}^T f_j(t + \tau)f_k(t)dt \quad (3.16)$$

Für den Fall $j \neq k$ werden die Kreuzkorrelationen $C_{j,k}$ berechnet, für $j=k$ wird die Autokorrelation berechnet. Mit dieser Formel wird die Autokorrelations-Kreuzkorrelationsmatrix

$$C_{j,k}(\tau) = \begin{pmatrix} C_{1,1}(\tau) & C_{1,2}(\tau) & \dots & C_{1,k}(\tau) \\ C_{2,1}(\tau) & C_{2,2}(\tau) & \dots & C_{2,k}(\tau) \\ \vdots & \vdots & \ddots & \vdots \\ C_{j,1}(\tau) & C_{j,2}(\tau) & \dots & C_{j,k}(\tau) \end{pmatrix} \quad (3.17)$$

berechnet. Für diese Matrix gilt die Symmetrie zur Hauptdiagonalen.

3.6 Neuronale Netze

Ein künstliches Neuronales Netz ist ein Zusammenschluss aus Neuronen, die in verschiedene Layer (Schichten) eingebettet sind. Diese Einzelbausteine besitzen die Eigenschaft sich zu aktivieren sobald ein Schwellwert erreicht wird, was zur Aktivierung von weiteren Neuronen führt. Für ein solches Neuronales Netz ist eine Anzahl an Eingangsneuronen (Input Layer) und Ausgangsneuronen (Output Layer) zu definieren, Neuronen zwischen diesen werden dem Hidden Layer zugeordnet. Das Netz soll anhand von Eingabeparametern den oder die Ausgabeparameter bestimmen. Durch die Gewichtung der Neuronen in jeder Iteration wird ein Lernprozess durch die sog. Backpropagation simuliert. Die Optimierung wird durchgeführt mit der Methode der kleinsten Quadrate. Das Netz approximiert eine Funktion zur Abbildung der Eingangsdaten. Ein Beispiel für ein Netz mit einem Hidden Layer, drei Input- und zwei Outputneuronen ist in der folgenden Abbildung 3.4 dargestellt.

Jedes Neuron besitzt eine individuelle Gewichtung und eine Aktivierungsfunktion, die im Regelfall für alle Neuronen gleich definiert ist. Das Gewicht stellt einen Wert dar, der mit dem Eingabewert verrechnet wird. Übersteigt dieses den Schwellwert der Aktivierungsfunktion, so wird das Neuron aktiviert und gibt ein Signal an das folgende Layer. Um Nullwerte verarbeiten zu können wird auf jeden Eingabewert eine Addition eines zu erlernenden Bias durchgeführt. Multiplikationen würden ohne diese Korrektur in jedem Fall einen Wert von Null als Output produzieren

Die Eigenschaften zum Aktivieren der Neuronen werden durch die eben genannte Aktivierungsfunktion bestimmt. Das bedeutet, dass die Neuronen ein Eingangssignal erhalten, das so lange summiert wird, bis der Schwellwert erreicht ist. Jedem Neuron




Abbildung 3.4: Beispiel eines Neuronalen Netzes mit einem Hidden Layer (Glosser.ca 2013).

wird zur Berechnung des Schwellwerts die übergeordnete Aktivierungsfunktion und eine individuelle Gewichtung zugewiesen. Etabliert haben sich nach Kriesel (1991) in der Vergangenheit folgende Aktivierungsfunktionen:

1. Sigmoid Funktion

- Funktion: $f(x) = \frac{1}{1+e^{-x}}$
- besitzt einen Wertebereich von 0 bis 1

2. Tangens-hyperbolicus Funktion

- Funktion: $f(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$
- besitzt einen Wertebereich von -1 bis 1

3. Rectifier linear unit (ReLU)

- Funktion: $f(x) = \max(0, x)$
- besitzt einen Wertebereich von 0 bis x

Das wichtigste Unterscheidungsmerkmal der Aktivierungsfunktionen ist der Wertebereich. Mit der ReLU Funktion ist es durch die lineare Skalierbarkeit möglich, Werte außerhalb der Grenzen der Testdaten zu verarbeiten, wodurch eine Vorhersage mit neuen Daten außerhalb des Definitionsbereichs durchgeführt werden kann. Zudem hat sich gezeigt, dass ReLU Netzwerke in vielen Fällen eine schnellere Laufzeit erzielen, ohne einem Qualitätsverlust des Netzwerkes zu unterliegen (vgl. Zhang u. a. 2018). Die Sigmoid Funktion und der Tangens hyperbolicus begrenzen hingegen den Output auf $[0,1]$ bzw. $[-1,1]$, was in Anwendungen Stabilität erzeugen kann. Zusätzlich ist es möglich mit der ReLU 'tote' Neuronen zu erzeugen. Diese haben eine Gewichtung von 0 und können nicht mehr aktiviert werden. Die Sigmoid Funktion und der Tangens hyperbolicus werden nie auf 0 fallen, gegen 0 konvergieren, womit die Chance besteht, die Neuronen zu reaktivieren. Die Gewichte werden durch Gradientenoptimierungsverfahren wie zum Beispiel AdaBoost angepasst (vgl. Schwenk und Bengio 1997).

In der folgenden Abbildung 3.5 sind die vorgestellten Aktivierungsfunktionen in einem Plot dargestellt. Dieser macht die Unterschiede der jeweiligen Funktionen sichtbar.

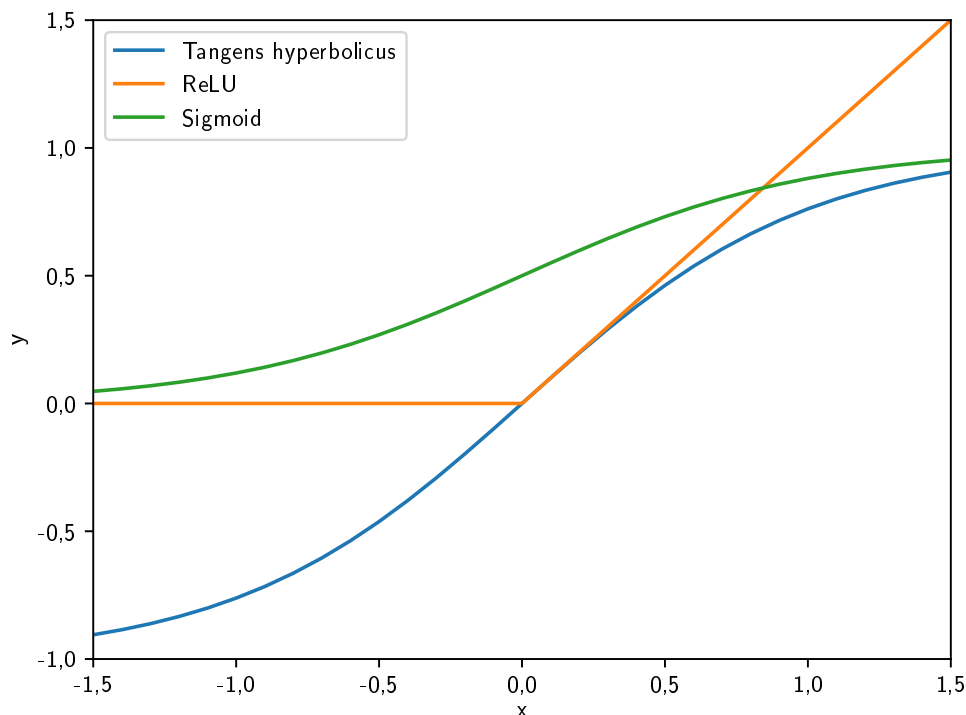


Abbildung 3.5: Die Aktivierungsfunktionen im Vergleich

Die drei Gates der LSTM Zelle können in der Abbildung 3.6 identifiziert werden.

1. Forget Gate:
Erster Layer (von links): entscheidet welche Informationen erhalten bleiben sollen.
2. Input Gate:
Zweiter Layer (von links) und tanh Funktion: entscheidet welche Informationen neu hinzugefügt werden.
3. Output Gate:
Dritter Layer(von links): entscheidet welche Information herausgegeben wird.

Ein bekanntes Problem beim maschinellen Lernen ist das sogenannte Overfitting (Überanpassung). Dieser Effekt tritt nach Kruse, Borgelt und Klawonn (2011) auf, wenn das Netz lange gelernt hat und die Gewichte zu groß werden. Auf diese Weise überwiegen die stark gewichteten Neuronen und das Netz verliert die Fähigkeit sich anzupassen. Der Gewichtungsverfall (weight decay) ist eine der ersten erfolgreichen Möglichkeiten, diesem Effekt entgegenzuwirken (vgl. Werbos und J. Paul John 1974). Die berechnete Gewichtung verringert sich anteilmäßig mit jedem Schritt und bietet den weniger einflussreichen mehr Möglichkeit zum Reaktivieren. Ein zweiter Effekt, der zum Overfitting führt ist, dass das Netz sich an einen Datensatz zu genau anpasst und nicht die gewünschte Funktion approximiert (Hinton u. a. 2012). In Abbildung 3.7 ist dies zu erkennen. Zwei Datensätze sollen voneinander separiert werden. Ein Neuronales Netz, das eine allgemeine Lösung gefunden hat, grenzt diese mittels einer Lösung wie der schwarzen Linie ab. Hingegen zielt ein Netz mit Overfitting auf die Abtrennung der einzelnen Datenpunkte ab (in grün eingezeichnet). Hier wurde zu lange mit denselben Daten trainiert und das Netz ist nur für diesen Datensatz sinnvoll verwendbar, verliert aber die Prediktionseigenschaften für andere Datensätze. Aus demselben Grund sind zu komplexe Netze ungeeignet, um einfache Funktionen zu erfassen.

Zur Behandlung dieses Problems wird das sogenannte Dropout (Srivastava u. a. 2014) verwendet. Dies führt zum Ausschalten zufälliger Neuronen in den Durchgängen des Trainings. Aufgrund der Komplexität der jeweiligen Aufgaben ist keine allgemeine Aussage über die ideale Rate zum Deaktivieren der Neuronen zu treffen. Srivastava u. a. (2014) empfehlen einen Prozentsatz von 20% bis 50% an Neuronen auszuschalten. Das Dropout bedeutet, dass das Netz nicht in der Lage ist, einen optimalen Zustand anzunehmen. Die Gewichtung der Neuronen findet kein Optimum und das Netz lernt allgemein mit dem Problem umzugehen. Hinton u. a. zeigen in ihrer Arbeit *Improving neural networks by preventing co-adaptation of*




Abbildung 3.7: Beispiel von Overfitting anhand von Randerkennung zwischen zwei Datensätzen (Rot/Blau). Schwarz: erwartetes Ergebnis, Grün: Overfitting (Chabacano 2008).

feature detectors, wie das Dropout das Ergebnis positiv beeinflusst und komplexe Strukturen verallgemeinert.

Ein weiteres Konzept, das im Hinblick auf Neuronale Netze und Zeitreihen erklärt werden soll, ist das Time-Distributed (zeitverteilte) Layer von Tensorflow 1.14 (vgl. *TensorFlow Core v1.14*). Diese Funktion wendet auf jeden Zeitschritt, der in Tensorflow verwendeten Tensoren, ein zusätzliches Layer an und ist bei Netzwerken mit retrospektiver Informationsgewinnung anzuwenden. Das bedeutet: Für jeden Zeitschritt wird ein unabhängiges Layer hinzugefügt. Die Vorteile hierbei sind:

- Nur die Werten zwischen ihrem eigenen Zeitschritt interagieren.
- Zwischen verschiedenen Zeitschritten und Kanälen kommt es nicht zu Interaktionen.

Die hier vorgestellten Methoden von Neuronalen Netzen sind ein Ausschnitt von den aktuell geläufigen Methoden und jener, die in dieser Arbeit verwendet wird. Aufgrund der Komplexität wird für weitere Grundlagen auf weiterführende Litera-

tur verwiesen (zum Beispiel: *Computational Intelligence: Eine methodische Einführung in Künstliche Neuronale Netze, Evolutionäre Algorithmen, Fuzzy-Systeme und Bayes-Netze* (Kruse, Borgelt und Klawonn 2011)).

3.7 Box-Jenkins Methode

Die Box-Jenkins Methode wurde nach den gleichnamigen Autoren des Monographie *Time series analysis: forecasting and control* benannt. In diesem Werk wird ein Verfahren zur Anwendung von linearen stationären und nicht-stationären Modellen, wie z.B. ARIMA, beschrieben. Die iterative Methode besteht für ein autoregressive-moving-average Modell (autoregressives gleitendes durchschnitts-Modell; ARMA) zusammengefasst aus drei Schritten (Box u. a. 1976):

1. Modellidentifikation:
Überprüfung, ob die Daten stationär sind, und ob eine saisonale Abhängigkeit besteht
2. Parameterschätzung:
Berechnen der besten Koeffizienten für das Modell
3. Prognose der Zeitwerte:
Erstellung und Validierung des Modells

Dieses Vorgehen wird wiederholt ausgeführt und die Validierung hilft dabei, die nächste Iteration zu verbessern. Die, im ersten Schritt erwähnten, Voraussetzungen eines stationären Prozesses, werden wie folgt definiert:(Levendis 2018):

- Der Mittelwert ist zeitlich unabhängig: $\mu(t) = \mu$
- Die Varianz ist zeitlich unabhängig: $\sigma^2(t) = \sigma^2$
- Die Korrelation ist zeitlich unabhängig:
$$Cov(X_t, X_{t+k}) = Cov(X_{t+1}, X_{t+k+1}) = Cov(X_{t-1}, X_{t+k-1})$$

Diese Definition bezieht sich auf die Eigenschaften der sogenannten "schwachen Stationarität". Diese reicht für die Anwendungen der Box-Jenkins Methode aus (Levendis 2018). Mittels verschiedener Methoden kann dies überprüft werden. Box u. a. verwenden die Autokorrelationsfunktion, die bei einem schwach stationären Pro-

zess keine Zeitabhängigkeit aufweist. Oftmals ist es möglich, durch Betrachtung der Daten Trends zu erkennen. Sollten diese Methoden nicht ausreichen, sind quantifizierbare Tests zu verwenden. Beispiele hierfür sind:

- Der Priestley-Subba Rao Test (Priestley und Rao 1969)
- Der Dickey-Fuller Test (Dickey und Fuller 1979)
- Der Leybourne-McCabe Test (Leybourne und McCabe 1994)
- Der Kwiatkowski-Phillips-Schmidt-Shin Test (Kwiatkowski u. a. 1992)

Für die Berechnung der Parameterschätzungen werden in der Literatur Maximum-Likelihood Schätzung oder die Methode der kleinsten Quadrate empfohlen (Box u. a. 1976). Für Schätzverfahren der Parameter wird an die jeweils angegebenen Literatur zu den jeweiligen Themen verwiesen und diese werden hier nicht weiter ausgeführt.

3.7.1 Univariate Modelle

Die bereits erwähnten Modelle wie ARIMA oder ARMA werden im Weiteren erklärt. Diese Modelle sind modular zu verstehen und bestehen, je nach Anwendung, aus verschiedenen Einzeloperatoren. Das ARIMA Modell besteht aus einem autoregressiven Prozess (AR), einer Integration (I) und dem gleitenden Mittelwert (MA). Dem ARMA Prozess wird hingegen ohne die Integration (I) modelliert (Box u. a. 1976).

Der autoregressive Prozess wird mit der Ordnung p wie folgt definiert (vgl. Gebhard und Jürgen 2006):

$$x_t = \delta + \alpha_1 x_{t-1} + \alpha_2 x_{t-2} + \dots + \alpha_p x_{t-p} + \mu_t \quad (3.18)$$

Es gilt $\alpha \neq 0$ und μ_t ist ein Zufallsprozess mit Erwartungswert Null. Dieses Modell beantwortet die Frage, inwiefern die Beobachtungen in der Vergangenheit die Beobachtungen in der Zukunft beeinflussen. Je höher die Ordnung des Prozesses gewählt wird, desto mehr Zeitschritte werden retrospektiv einbezogen.

Der Prozess des gleitenden Mittelwertes der Ordnung q ist durch folgende Gleichung gegeben (Gebhard und Jürgen 2006):

$$x_t = \mu + \mu_t - \beta_1\mu_{t-1} - \beta_2\mu_{t-2} - \dots - \beta_q\mu_{t-q} \quad (3.19)$$

Dieses Modell verwendet vorherige Zeitschritte t_q mit der Gewichtung β_q zur Korrektur des Mittelwertes μ , wobei gilt: $\beta_q \neq 0$ und μ_t ist ein reiner Zufallsprozess mit Erwartungswert Null. Somit wird die Information der vorherigen Abweichung vom Mittelwert als Korrektur zur aktuellen Berechnung verwendet. Auch hier wird ein schwach stationärer Prozess benötigt, da der Mittelwert und die Abweichung vom Mittelwert zeitlich unabhängig sein müssen.

Kombiniert man beide vorgestellten Prozesse (Formeln 3.18 und 3.19), so entsteht das ARMA Modell. Es verbindet die Eigenschaften des AR und MA Modells und wird mit der Schreibweise ARMA(p,q) dargestellt. p ist die Ordnung des AR Modells und q die Ordnung des MA Modells. Der allgemeine autoregressive moving average Prozess lässt sich, mit den Bedingungen von Modulprozessen, schreiben als:

$$x_t = c + \alpha_1x_{t-1} + \dots + \alpha_px_{t-p} + \mu_t - \beta_1\mu_{t-1} - \dots - \beta_q\mu_{t-q} \quad (3.20)$$

Das ARMA Modell ist die Grundlage für zahlreiche weitere Modelle, bei denen jedes das ARMA Modell entsprechend der Aufgabenstellung anpasst. Durch die Modularität können verschiedene Methoden kombiniert werden.

Viele Daten verhalten sich so, als besäßen sie keinen festen Mittelwert. Zum Beispiel ist der Firmenumsatz bei einer Aufschwungphase mit einem Trend versehen, woraufhin das ARMA Modell nicht mehr anwendbar ist. Für nicht-stationäre Datensätze wurden mehrere ARMA Erweiterungen entwickelt, von denen zwei vorgestellt werden. Der autoregressive integrated moving average (ARIMA) Prozess ist die Erste. Bei diesem wird durch Differenzbildung schwache Stationarität erzeugt. Der Backshiftoperator L bewirkt bei einer Prozessvariable eine Verschiebung um eine Zeiteinheit zurück: $Lx_t = x_{t-1}$. Nach Jürgen (2015) definiert sich der ARIMA Prozess erster Ordnung wie folgt:

$$(1 - L)x_t = x_t - x_{t-1} \quad (3.21)$$

Durch d-fache Anwendung $(1 - L)^d$ können nichtlineare Trends der Ordnung d entfernt werden. Die Schreibweise des ARIMA Prozesses erweitert den ARMA Prozess um die Ordnung d : ARIMA(p,d,q) (Jürgen 2015). Ein ARIMA Prozess der Ordnung (p,0,q) ist ein ARMA Prozess.

Für periodische Einflüsse in den Daten wird das ARIMA Modell um einen saisonalen Einflussfaktor ergänzt. Dies wird als Saisonale-ARIMA (SARIMA) bezeichnet. Dies ist für Daten wie Verkaufszahlen mit Unterschieden im Sommer und Winter geeignet. Generalisiert betrachtet sollen diese Einflüsse durch das Modell ausgeglichen werden. Das SARIMA Modell wird notiert als $ARIMA(p, d, q) \times (P, D, Q)_m$ und lässt sich mit dem Zufallsprozess μ_t über folgende Formel beschreiben(vgl. Jürgen 2015):

$$\Phi_p(L)\tilde{\Phi}_P(L^m)(1 - L)^d(1 - L^m)^D x_t = \Theta_q(L)\tilde{\Theta}_Q(L^m)\mu_t \quad (3.22)$$

Die charakteristischen Polynome Φ_p und Θ_q bzw. $\tilde{\Phi}_P$ und $\tilde{\Theta}_Q$ dürfen keine gemeinsamen Wurzeln haben und müssen Nullstellen außerhalb des Einheitskreises besitzen (Jürgen 2015). Die zu konfigurierenden Parameter sind ähnlich wie beim ARIMA Modell die Ordnung D der Integration und die Polynomgrade P und Q für den saisonalen Einfluss. m steht für die Anzahl an Zeitschritte pro Periode.

Die vorgestellten Modelle stellen einen fundamentalen Überblick zur Zeitserienanalyse nach der ARMA Methodik dar. Weitere Prozesse sind für zusätzliche Problematiken zugänglich (z.B. ARMAX Modell). Je nach Anwendungsfall muss das geeignete Modell nach dem Ansatz der Box-Jenkins Methode gewählt werden.

Die Box-Jenkins Methode ist eine fundierte Vorgehensweise, um Zeitserienmodelle zu erstellen. Mit 50 bis 100 Zeitpunkten als empfohlene Mindestdatengröße für ein ARIMA Modell ist der Aufwand zur Datenerfassung überschaubar (vgl. Box und Tiao 1975. Lehrbücher verwenden für einfachere Modelle wie AR oder MA Beispiele mit weniger Beobachtungen (vgl. Box u. a. 1976 und Gebhard und Jürgen 2006).

Ein Nachteil dieser Methode ist die eingeschränkte Nutzbarkeit. Der Rechenaufwand ist nicht zu vernachlässigen, da für jeden Zeitschritt eine Summe der Ordnungen (p,d,q) berechnet werden muss. Für eine höhere Anzahl der jeweiligen Ordnung steigt die benötigte Rechenzeit an. Des Weiteren streuen die Modelle stark, je mehr Daten prognostiziert werden (vgl. Box u. a. 1976).

3.7.2 Multivariate Modelle

Bisher wurden Modelle zur univariaten Prognose von Zeitserien vorgestellt. Für Anwendungen wie die Produktlebensdaueranalyse, die mit multivariaten Datenlagen arbeiten, gibt es mehrdimensionale Modelle. Die Autoregression (siehe Formel 3.18) wird mit mehrdimensionalen Merkmalen, einem Vektor y_t mit n Variablen zum Zeitpunkt t ($n \times 1$), beschrieben. Die daraus entstehende Vektor Autoregression (VAR) wird nach Hamilton(1994) definiert über:

$$y_t = \delta + A_1 y_{t-1} + A_2 y_{t-2} + \dots + A_p y_{t-p} + \mu_t \quad (3.23)$$

Mit μ_t als n -Vektor der Zufallsprozesse der Variablen und A_i als zeit-invariante Matrix der Form $n \times n$ entsteht der multidimensionale Ansatz zur Zeitserienanalyse. Das VAR Modell kann mit anderen Prozessen verknüpft werden. So entstehen VAR-MA, VARIMA oder ähnliche Prozesse. Die Komplexität der Rechenschritte macht multivariate Modelle zeitaufwändiger als univariate.

4 Methodik

In diesem Kapitel werden die allgemeinen Methoden des Standes der Technik (Kapitel 3) hinsichtlich uni- und multivariater Zeitreihenanalyse bewertet und für die weitere Bearbeitung der Akteurendaten analysiert. Diese Diskussion ist notwendig, um geeignete Methoden für den Anwendungsfall zu bestimmen. Das weitere Vorgehen wird als Ergebnis im nachfolgenden Kapitel angewandt.

4.1 Diskussion der Prognosemethoden

Nicht jede Methode ist für die Auswertung der vorgestellten Daten aus Kapitel 2.4 geeignet. Die aufgezeichnete Messung der Auslenkung soll auf multivariate Einflüsse untersucht werden. Zudem zeigt die Abbildung 2.3 verschiedene Eigenschaften im zeitlichen Verlauf auf. Es sind mindestens drei unterschiedliche Ereignisse zu erkennen:

1. Anspannungsphase:
Der Draht spannt den Akteur.
2. Maximum:
Die maximale Auslenkung des Drahtes.
3. Ruhephase
Die Rückstellung in die Ausgangsposition.

Methoden, wie die Regression oder Splines benötigen eindeutige diskrete Zustände, um angewandt werden zu können. Hess und Bracke (2019) beschreiben ein Vorgehen, bei dem die Maxima aus den Messdaten extrahiert werden. Auf diese werden Methoden wie die Korrelationsanalyse, Hampel-Filter (vgl. Pearson 1999), die lineare Regression und Verteilungsanpassung angewandt. Dieses Vorgehen setzt voraus, dass die Degradation in den Messdaten der Maxima zu erkennen ist. In Kapitel 2.2 sind drei Degradationserscheinungen eingeführt worden. Die Änderung von physikalischen Eigenschaften oder Rissfortschritt sind keine Materialermüdungen, die Einfluss auf diese Maxima nehmen. Zu erwarten ist, dass bei einem Rissfortschritt das Bauteil Schwankungen unterliegt und bei Veränderung von physikalischen Ei-

enschaften die Ruhe- und Anspannungsphase anders verläuft. Um diese Effekte zu erkennen, werden alle Ereignisse der Messung betrachtet.

Die Box-Jenkins Methode mit dem vorgestellten ARIMA/ARMA Modell ist eine Möglichkeit zur Zeitserienbetrachtung, die im weiteren Verlauf diskutiert wird. Aufgrund der Periodizität der Messdaten muss das SARIMA Modell angewandt werden. Eine Schwierigkeit hierbei ist, dass mehrere periodische Vorgänge, wie zum Beispiel die Ruhephase, stattfinden. Das SARIMA Modell ist für einzelne periodische Vorgänge ausgelegt. Die saisonale Zerlegung von Zeitreihen kann durch Methoden wie die lokale lineare Kernel-Regression oder dem gleitenden Mittelwert durchgeführt werden (vgl. Cleveland, Cleveland und Terpenning 1990). Die mehrfache Anwendung erzeugt einen weiteren unerwünschten Informationsverlust. Ein weiterer Nachteil ist der Rechenaufwand, der durch die Summen in den Modellen entsteht. Die Modelle funktionieren, indem Informationen aus vorherigen Datenpunkten in die Prognose einfließen. Bei ca. 160 Daten pro Messzyklus sind hohe Ordnungen der Prozesse notwendig, um Informationen aus vorangegangenen Perioden zu gewinnen. Das bedeutet im Umkehrschluss, dass z.B. bei 3 Perioden allein für einen AR Prozess 480 Summen pro prognostizierten Datenpunkt berechnet werden müssen. Soll eine ganze Periode prognostiziert werden, so sind 76800 Summen zu berechnen. Mit der Annahme, dass die Degradation ein schleichender Prozess ist, sind viele Perioden zu involvieren. Die Rechenzeit steigt exponentiell an, womit das Vorgehen für große Datenmengen nicht umsetzbar ist. Die Modelle der Box-Jenkins Methode sind ungeeignet für die vorliegenden Dauerprüfversuche. In anderen Anwendungsfällen ist eine Umsetzung möglich. Zum Beispiel ist die Anwendbarkeit für einen Fall mit Datenreduktion, wie die Maximaextraktion nach Hess und Bracke (2019), gegeben.

Für Neuronale Netze sind große Datenmengen erforderlich zum erfolgreichen Lernen. Im Vergleich zu den Methoden von Box und Jenkins stellen periodische Einflüsse für die Methode keine Fehlerursache dar (vgl. Rey und Wender 2018). Im direkten Vergleich zu Box-Jenkins Methode erzielen Neuronale Netze präzisere langfristige Vorhersagen (Tang, Almeida und Fishwick 1991). Für kurzfristige Prognosen sind Methoden nach dem Vorgehen von Box und Jenkins vorzuziehen. Ein Nachteil der Netze ist, dass die Komplexität der Berechnung und somit der Rechenaufwand von der jeweiligen Modellauslegung abhängt. Zusätzlich zu den langen Trainingsphasen besteht das Problem, dass ein Netz nicht durch Optimierungsfunktionen, wie kleinste Quadrate oder Maximum Likelihood, erstellt werden kann. Die Aufstellung benötigt viel Zeit, Fachwissen und dynamische Anpassungen, um ein geeignetes Modell zu kreieren (vgl. Rey und Wender 2018). Neuronale Netze sind durch das Inputlayer grundsätzlich multivariat. Der Einfluss der Variablen ist im Netz durch die Gewichtung dargestellt, diese sind schwer oder überhaupt nicht nachzuvollziehen bei komplexen Anwendungen. Ein mögliches Vorgehen ist, mehrere Netze mit verschiedenen Eingangsparametern zu trainieren und auf Abweichungen zu achten.

Die vorgestellten mathematischen Modelle der Fourieranalyse sind durch einfache Multiplikation vergleichsweise zeiteffizient. Die theoretische Annahme, dass die Funktion durch Frequenzen dargestellt und prognostiziert wird, stellt eine Möglichkeit dar, das gesamte Verhalten des Prüfvorgangs zu quantifizieren. Eine Problematik, die dabei auftritt, ist die Interpretationsmöglichkeit der Ergebnisse. Auch wenn die Funktion abgebildet werden kann, müssen die einzelnen Komponenten analysiert und die Frequenzen den Vorgängen zugeordnet werden. Bestehen keine Informationen durch Daten über die einzelnen Elemente, ist die Interpretation aufwändig. Multivariate Einflussfaktoren können auf diese Weise nur mit Datengrundlage über diese gefunden werden.

Eine Zusammenfassung der Ergebnisse dieser Diskussion ist in Tabelle 5.8 dargestellt. Es wird bewertet, ob die Methode Informationen aus großen Datenmengen gewinnen kann, wie die Rechenzeit skaliert, also ob diese mit wachsender Komplexität stark ansteigt, ob vorher eine Datenverdichtung vorgenommen werden muss und ob diese multivariat eingesetzt werden kann.

Tabelle 4.1: Vergleich der Methoden in Bezug auf Anwendungsmerkmale

| <div>Anforderung:</div> <div>Methode:</div> | große Datenmengen | Recheneffizienz | keine Datenverdichtung | multivariat anwendbar |
|---|-------------------|-----------------|------------------------|-----------------------|
| Lineare Methoden | ✓ | ✓✓ | ✗ | ✓ |
| Box-Jenkins Methode | ✗✗ | ✗ | - | ✓ |
| Neuronale Netze | ✓✓ | ✗ | ✓ | ✓✓ |
| Fourieranalyse | ✓ | ✓✓ | ✓ | ✓ |

4.2 Methodik zur Anwendung am Beispiel der Aktorentechnologie

Im vorangegangenen Unterkapitel 4.1 wurden die Methoden auf Hinblick der Auswertung am Aktorendatensatz diskutiert. Tabelle 5.8 dient als Grundlage zur Anwendung auf den realen Datensatz. Die Grundlage zur Auswertung und einen Überblick über die Daten verschafft die Autokorrelation. Diese wird mittels des Wiener Khinchin Theorems ermittelt. Wie in der Definition (Kapitel 3.5.2) beschrieben, eignet sich dieses für große Datenmengen aufgrund der Zeiteffizienz gegenüber dem diskreten Vorgehen.

Methoden, die eine Datenverdichtung benötigen, werden nicht angewandt, da die Degradationseinflüsse in allen Phasen der Messung auftreten können. Somit werden die linearen Methoden und das Box-Jenkins Vorgehen, das eine Datenverdichtung zwecks der Saisonalität benötigt, in der Auswertung nicht berücksichtigt.

Auf Basis der Autokorrelation und der bereits durchgeführten Fouriertransformation ist die Analyse im Frequenzbereich naheliegend. Diese wird auf die Daten angewandt. Mittels der Ergebnisse und der erwarteten Veränderung im Spektrum oder der Amplituden soll Degradation erkannt und gegebenenfalls bestimmt werden. Der Einfluss der Parameter wird durch die Autokorrelation und die Frequenzen untersucht. Die Fourierreihe wird anschließend zur Approximation weiterer Anwendungszyklen verwendet. Eine Validierung des Prognosergebnisses findet im Zusammenhang mit der Quantifizierung durch Kennzahlen statt.

Das zweite angewendete Modell ist das Neuronale Netz. Dieses wird erstellt und mit verschiedenen Eingabeparametern trainiert. Die Ergebnisse zur Prognose werden anschließend identisch zur Spektralanalyse verifiziert und bewertet. Der multivariate Einfluss wird mittels der Diversität des Inputs überprüft.

Anschließend werden die Ergebnisse gegenübergestellt und interpretiert. Eine Fehlerdiskussion schließt die Anwendung der Methoden ab.

5 Auswertung am vorgestellten Datensatz

Die in 3 vorgestellten Methoden werden anhand eines Realdatensatzes umgesetzt. Dieser wird, anhand des Prüfplatzes für Formgedächtnislegierungen (siehe Kapitel 2) erstellt. Am Ende werden die angewandten Methoden gegenübergestellt und bewertet.

5.1 Autokorrelation

Die Analyse der Autokorrelation ist, im Gegensatz zu den anderen Methoden, kein Tool zur Prognose des Datensatzes. Die Autokorrelationsfunktion gibt einen Überblick über das Verhalten des Datensatzes im zeitlichen Verlauf. Die Funktion wird nach dem Wiener-Kintchine Theorem berechnet, da dieses für große Datensätze zeiteffizienter ist (siehe Kapitel 3.5.2). Für die nachfolgenden Korrelogramme wird die normierte Darstellung gewählt worden. Es wird auf das Lag 0 normiert, da dieses den Wert 1 besitzt.

Das Ergebnis der Autokorrelationsfunktion der Auslenkung eines Aktors aus Datensatz 2 ist in der folgenden Abbildung 5.1 dargestellt. Das periodische Verhalten des Prüfaubaus ist hier in Form von Antikorrelationen (negative Werte der Autokorrelationsfunktion) zu sehen. Die Korrelation nimmt bis ca. 3.500 Lags ab und ist ab diesem Zeitpunkt nicht mehr gegeben. Die Abnahme der Werte am Ende des zeitlichen Verlaufs lässt sich auf den Bruch zurückführen, da ab diesem Zeitpunkt eine Konstante gemessen wird. Dieser Einfluss macht sich schleichend bemerkbar und ist auch für den Offset über dem Nullwert verantwortlich. Zusätzlich ist die im Kapitel 3.5.2 erwähnte Ungenauigkeit mit zunehmenden Einfluss in Form von Artefakte sichtbar.




Abbildung 5.1: Autokorrelation der Messreihe des zweiten Datensatzes: Auslenkung von Akteur 1.

Aus dieser Analyse lässt sich eindeutig zeigen, dass sich im zeitlichen Verlauf die Funktion schnell ändert und nach der kurzen Zeit von ca. 3.500 Lags keine Ähnlichkeit mit dem Anfang aufweist. Die Artefakte sind bei ca. 10^7 Lags zu erkennen, dort sind zu wenig Datenpunkte zur Berechnung vorhanden. Die Auswertung der weiteren Aktorenmessreihen befindet sich in Anhang A. Für Datensatz 1 ist der Brucheinfluss nicht zu erkennen, die Autokorrelationsfunktionen verlaufen hingegen identisch.

Der Fokus wird auf den Vergleich der Auslenkung mit den anderen Variablen, der Temperatur und dem Widerstand gelegt. Die Funktion der Temperaturänderung (Abbildung 5.2) bleibt den Messverlauf über konstant und schwingt am Ende aus. Die Änderung im Verhalten bei ca. $5 \cdot 10^6$ Lags ist auf die ausfallenden Aktoren zurückzuführen, da dieser Wärme erzeugt. Nach dem Ausfall bleibt diese Wärmeänderung aus. Daher ändert sich die Autokorrelationsfunktion nach den Ausfällen der Aktoren. Die Werte außerhalb der Normierung von -1 und 1 sind auf die fehlenden Datenpunkte am Ende der Berechnung zurückzuführen. Ab ca. $6 \cdot 10^6$ Lags reichen die Daten nicht mehr aus.




Abbildung 5.2: Autokorrelation der Messreihe des zweiten Datensatzes: Temperatur.

Der Widerstand verhält sich wie die Auslenkung der FGL Drähte (vgl. Abbildung 5.3). Dies erklärt sich aus der direkten Abhängigkeit der Spannung von der Auslenkung. Bei ungefähr 3.500 Lags stellt sich die Autokorrelation der Funktion ein. Im Vergleich zur Abbildung 5.1 ist der weitere Verlauf weniger beeinflusst. Es entstehen weniger Artefakte und aufgrund der nicht wegfallenden Spannung und Strommessung ist keine Bruchstelle zu erkennen.




Abbildung 5.3: Autokorrelation der Messreihe des zweiten Datensatzes: Widerstand.

Die Spannung und somit auch der Widerstand stehen im direkten Zusammenhang zueinander. Die Temperatur hingegen ist eine Eingangsgröße, die nicht mit den Anderen verglichen werden kann, da ein schleichender Einfluss zu erwarten ist. Die Berechnung der Kreuzkorrelationen nach Formel 3.17 wird daher nicht angewandt. Mit dieser Analyse der Autokorrelationsfunktionen werden Verhaltensweisen des zeitlichen Verlaufes verschiedener Messgrößen aufgezeigt. Die Spannung und der Strom, dargestellt durch den Widerstand, verhalten sich wie die Auslenkung der FGL Aktoren und besitzen eine direkte Abhängigkeit. Die Funktion der Temperatur ist über die gesamte Messreihe, bis zum Wegfallen der Belastungen im Prüfaufbau, gleich. Falls die Temperaturschwankungen einen Einfluss haben, ist dieser nicht im direkten Vergleich der Autokorrelationsfunktionen erkennbar.

5.2 Fourier-Analyse

Die, in Unterabschnitt 3.2.1 vorgestellte Fouriertransformation kann auf die vorliegenden Daten angewandt werden. Dabei wird das Ergebnis hinsichtlich Degradation analysiert und interpretiert. Eine Prognose der Daten wird mittels der Berechnung der Auslenkungsfunktionen der Aktoren durchgeführt.

Die Fouriertransformation wird auf den gesamten Datensatz angewandt. Mit einer Abtastrate T von sechsmal pro Sekunde ergibt sich das in Abbildung 5.4 dargestellte Ergebnis:




Abbildung 5.4: Spektrogramm für die Fouriertransformierte der Aktorendaten.

Es sind verschiedene Frequenzen zu erkennen, die interpretiert werden. Die Frequenz mit dem größten Einfluss stellt die Grundfrequenz der zyklischen Wiederholung des Aktorenversuches dar. Das Anlegen der Spannung erfolgt in regelmäßigen Abständen von 25s. Daraus resultiert die Frequenz von $0.04\frac{1}{s}$, die in dem Spektrogramm dominiert, alle weiteren Größen sind Resultierende, wie zum Beispiel die Rückstellung der Feder.

Für eine Interpretation des Spektrums muss dieses zu unterschiedlichen Zeitpunkten verglichen werden. Hierfür wird der Datensatz in gleichgroße Teile aufgeteilt, sog. Chunks. In dieser Arbeit wird die Anzahl von Chunks auf 50 festgelegt. Beim ersten Datensatz entspricht ein Chunk ca. 3.849 Zyklen und somit einer Messzeit von 102.000s. Der zweite Datensatz wird in 2.798 Zyklen (74.147 Sekunden Messzeit) große Chunks unterteilt.

In Abbildung 5.5 ist zu erkennen, dass bei dem Versuch ohne Ausfall eine Verringerung des Spektrums vorliegt. Die Frequenzen ändern sich nicht signifikant. Die Auslenkungen des Drahtes scheinen jedoch mit der Zeit abzunehmen.




Abbildung 5.5: Spektrogramm für die Fouriertransformierte der Aktorendaten - Versuch ohne Ausfall.

Anders ist es bei dem Datensatz mit Ausfall, wie in Abbildung 5.6 zu erkennen ist. Im Vergleich zum fehlerfreien Datensatz sind deutliche Schwankungen in der Breite der Frequenzen vor dem Ausfall ersichtlich. Dieses Verhalten deutet auf einen unruhigen Messverlauf. Daraus lässt sich schließen, dass das Bauteil oder die Prüfvorrichtung nicht über die gesamte Prüfdauer gleichmäßig funktioniert und stellt somit ein Anzeichen von Fehlverhalten oder Degradation dar.




Abbildung 5.6: Spektrogramm für die Fouriertransformierte der Aktorendaten - Versuch mit Ausfall.

Erwartungsgemäß ändert sich die Temperatur im niedrigen Frequenzbereich. Die physikalischen Eigenschaften und der Messaufbau verhindern einen schnellen Temperaturanstieg an dem eingebauten Messfühler. Durch die Überlagerung des Temperaturspektrums und des Auslenkungsspektrums ist zu erkennen, dass bei $0.04\frac{1}{s}$ eine Übereinstimmung stattfindet. Diese Frequenz steht für die Anlegung der Spannung zum Erhitzen der FGL-Drähte, wobei die resultierende Wärme als gering erfasst werden kann. Obwohl das Spektrum in höheren Frequenzbereichen einen ähnlichen Verlauf besitzt, sind keine weiteren Überschneidungen zu erkennen.




Abbildung 5.7: Fourierspektrum der Temperatur.

Ein Einfluss der Umgebungstemperatur auf die Aktoren ist nicht auszuschließen, wobei ein direkter Einfluss der Temperaturänderung und der Aktoren nur bei der Grundfrequenz $0.04\frac{1}{s}$ zu beobachten ist. Die Problematik hierbei ist das ungeeignete Messverfahren der Temperatur. Die Funktion dieser Aktoren wird durch die Wärmeänderung aktiviert, wodurch ein direkter Einfluss des Testergebnisses mit der Umgebungstemperatur zu erwarten ist. Es ist auch möglich, dass dieser Einfluss zu gering ist und die Degradation in dem Temperaturbereich nicht beobachtbar beschleunigt oder verlangsamt wird.

Die vorherigen Analysen stellten eine qualitative Auswertung dar. Sie zeigten, wie das Spektrum sich über die Zeit verändert. Zur Prognose muss eine Quantifizierung stattfinden. Hierfür werden einzelne Bereiche der Frequenzen verwendet und deren Standardabweichung ermittelt, diese sind manuell auf Grundlage der Spektrogramme festgelegt. Die Standardabweichung σ wird berechnet durch (Papula 2014):

$$\sigma_x := \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2} \quad (5.1)$$

Ein Bereich wird durch eine untere Spezifikationsgrenze (lower specification limit (LSL)) und einer oberen Spezifikationsgrenze (upper specification limit (USL)) definiert. Es werden die markanten Frequenzen zu relevanten Frequenzbereichen zusammengefasst. Die verwendeten fünf Bereiche sind:

1. LSL:0,025 USL:0,050
2. LSL:0,065 USL:0,090
3. LSL:0,010 USL:0,125
4. LSL:0,135 USL:0,165
5. LSL:0,175 USL:0,200

Der hierzu erstellte Plot dient der Darstellung des zeitlichen Verlaufes der Standardabweichung je Chunk. In Abbildung 5.8 sind steigende Schwankungen im Frequenzbereich zu erkennen, was auf einen unruhigeren Messverlauf mit steigender Anzahl an Messzyklen schließen lässt. Dies ist ein, auf die Frequenz der Auslenkungsfunktion zurückzuführendes, Anzeichen für sich verändernde Messverhältnisse aufgrund der stattfindenden Degradation der Aktoren. Die äquivalente Graphik für Datensatz 1 ist in Anhang B dargestellt.

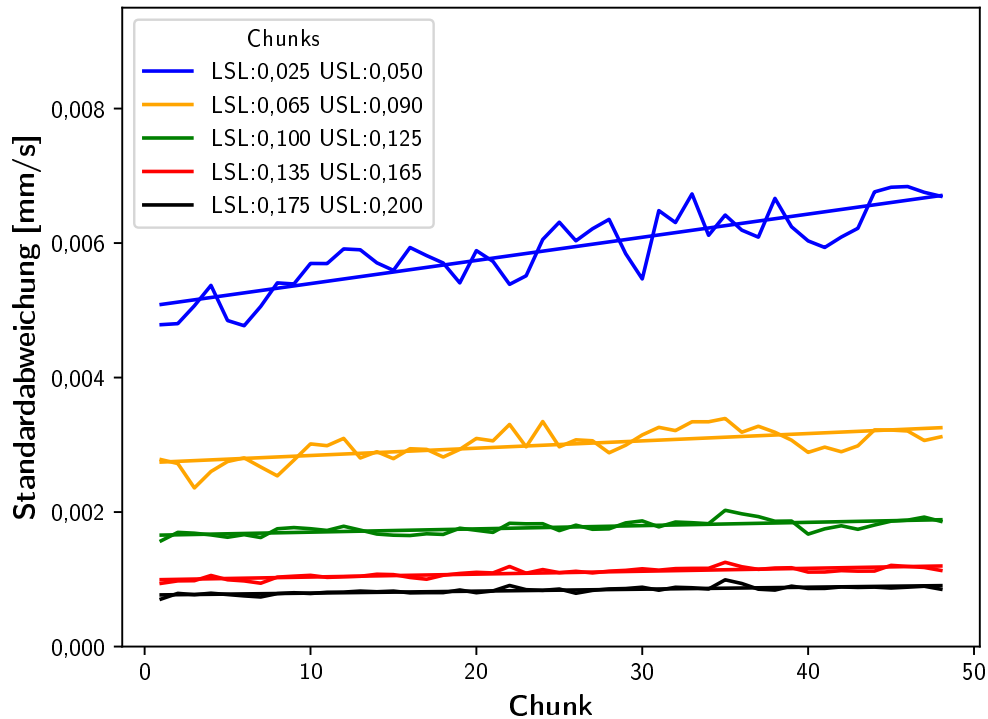


Abbildung 5.8: Standardabweichungen des Spektrums, zeitlicher Verlauf durch Chunks dargestellt; Datensatz 2.

In Anhang (B) sind alle Zahlenwerte beider Datenreihen zu finden. Zusätzlich wurde der Wald-Wolfowitz-Test (Wald und Wolfowitz 1940) angewandt, um die Verteilung der Standardabweichung auf Zufälligkeit zu testen. Die Nullhypothese ist hierbei, dass die Werte einen zufälligen Charakter aufweisen.

Bei dem Vergleich der beiden Datensätze fallen die unterschiedlichen Fits auf. Bei Datensatz mit Ausfall sind die Regressionen mit einem deutlich höheren r^2 zu erkennen und der Wald-Wolfowitz-Test ergibt in nahezu jedem Fall die Alternativhypothese: Die Standardabweichung ist nicht zufällig in ihrem Auftreten. Der Datensatz ohne Ausfall verhält sich ohne nennenswerte Einflüsse: Die Nullhypothese des Tests wird größtenteils akzeptiert und die linearen Regressionen besitzen einen sehr niedrigen r^2 Wert.

Aufgrund dieser Ergebnisse lassen sich folgende Schlüsse ziehen:

- In Datensatz 1 verändern sich die Frequenzen nicht signifikant.
- In Datensatz 2 ändern sich die Frequenzen mit der Zeit.

Dieses Verhalten spricht nicht für eine Degradation eines Bauteils. Es wurden jeweils 5 und 6 Aktoren vermessen, wobei die Datensätze sich grundlegend anders verhalten. Aus der Annahme, dass die Bauteile aus der gleichen Herstellung stammen, ergibt sich die nächste Annahme: Der Prüfaufbau unterscheidet sich bei den Datensätzen. Eine These hierzu ist, dass der Prüfplatz mit Ausfall einen Mangel besitzt und daher ein schleichender Fehler auftritt. Daher ist es unwahrscheinlich, dass dies ein sichtbarer Degradationseinfluss ist. Bei Datensatz 1 ist keine Degradation festzustellen. Das Bauteil verhält sich, in der Bezug auf die betrachteten Frequenzen am Ende so wie am Anfang. Im Gegensatz zum Autokorrelationsdiagramm wurden für diesen Ansatz nur wenige Frequenzen ausgesucht.

Die Änderung der Gesamtfunktion und somit die Degradation lassen sich mit diesem Ansatz nicht weiter bestimmen. Der Degradationseinfluss ist, falls vorhanden, in diesen Daten zu gering, um erkannt zu werden. Erwartungsgemäß stellt das Materialversagen einen Einfluss mit einer sehr niedrigen Frequenz dar, da dieser über alle Messzeiten schleichend Einfluss nimmt. Hier ist der Ausschlag zu niedrig, um ihn signifikant vom Grundrauschen zu unterscheiden (siehe Abbildung 5.6 und Abbildung 5.5).

Zusätzlich zur Analyse der Frequenzen erfolgt, anhand der in Kapitel 3.2.2 vorgestellten Formeln, die Approximation der Daten in Hinblick auf die Produktlebensdauer. Der Ansatz hierbei ist, die Funktion $f(x)$ der Auslenkung zu prognostizieren und die Güte der Prognose zu bestimmen. Aufgrund der großen Datenmenge ist die Methode der Fourierreihe nicht zeiteffizient und benötigt eine lange Rechenzeit. Daher wird ein komplexes Modell mit allen Daten für den jeweils ersten Aktor verwendet. Die weiteren Aktoren erhalten einen reduzierten Datensatz und weniger Fourierkoeffizienten n zur Berechnung. Für die Zensur werden die letzten Messwerte aus der Zeitreihe verwendet. Die Tabelle 5.1 verdeutlicht die Unterschiede in den Prognosemodellen.

Tabelle 5.1: Gegenüberstellung der verwendeten Daten für die Fourierreihenapproximation

| Großes Modell | Kleines Modell |
|-------------------------------------|-----------------------------------|
| $2 \cdot 10^7$ Datenpunkte | $4 \cdot 10^6$ Datenpunkte |
| $5 \cdot 10^6$ Fourierkoeffizienten | $\cdot 10^6$ Fourierkoeffizienten |

Nach der Berechnung der Funktion $f(x)$ mittels der Koeffizienten (Formeln 3.3-3.6) können diese gefiltert werden. Viele der berechneten Koeffizienten nehmen hierbei einen Wert nahe Null an. Dies hat den Vorteil, dass die überlagerte Funktion gefiltert werden kann und das Rauschen entfernt wird. Mit der Annahme, dass die Degradation und andere Einflüsse in diesem Bereich vorhanden sind, werden alle Fourierkoeffizienten verwendet. Eine Filterung findet nicht statt. Die Approximation wird quantifiziert mit der mittleren quadratischen Abweichung (mean squared error (MSE), vgl. Rüschenhof 2014):

Die mittlere quadratische Abweichung ist ohne Verschiebungssatz somit die Varianz. Die Ergebnisse der Prognose sind in der nachfolgenden Tabelle 5.2 zusammengefasst.

Tabelle 5.2: Ergebnisse der Approximation der Aktorendaten mittels der Fourierreihe, quantifiziert durch die mittlere quadratische Abweichung (MSE).

| Datensatz | Aktor | mittlere quadratische Abweichung (MSE) |
|-----------|------------|--|
| 1 | 1 | $4,71 \cdot 10^{-6}$ |
| 1 | 2 | $3,41 \cdot 10^{-6}$ |
| 1 | 3 | $8,55 \cdot 10^{-5}$ |
| 1 | 4 | $4,32 \cdot 10^{-4}$ |
| 1 | 5 | $5,35 \cdot 10^{-8}$ |
| 1 | 6 | $4,24 \cdot 10^{-9}$ |
| 1 | Mittelwert | $8,76 \cdot 10^{-5}$ |
| 2 | 1 | $5,20 \cdot 10^{-2}$ |
| 2 | 2 | $6,23 \cdot 10^{-2}$ |
| 2 | 3 | $7,67 \cdot 10^{-2}$ |
| 2 | 4 | $6,43 \cdot 10^{-2}$ |
| 2 | 5 | $6,34 \cdot 10^{-2}$ |
| 2 | 6 | $6,68 \cdot 10^{-2}$ |
| 2 | Mittelwert | $6,43 \cdot 10^{-2}$ |

Die Ergebnisse weisen auch hier einen Unterschied in den Daten auf. Die Prognose von Datensatz 1 gelingt mit einem durchschnittlichen Fehler von $8,76 \cdot 10^{-5}$ mm, was bei einer angenommenen Auslenkung von 0,6mm eine Abweichung von 0,015% darstellt. Die ungenaueste Prognose von Datensatz 2 besitzt hingegen einen durchschnittlichen Fehler von $6,43 \cdot 10^{-2}$ mm, was bei selbiger Annahme von 0,6mm eine Abweichung von 10,72% bedeutet. Die Prognose anhand der Fourierreihen zeigt erneut den Unterschied in den Datengrundlagen auf und deckt sich mit der vorherigen Betrachtungsmethode der Frequenzspektren. Datensatz 1 besitzt eine kontinuierliche Funktion, bei der die Approximation mit einem vernachlässigbaren kleinen Fehler stattfindet, Datensatz 2 besitzt hingegen Einflussgrößen, die bei der Analyse

der Fourierreihen nicht erfasst wurden und somit einen Fehler von ca. 11% bei der Prognose erzeugen.

Die kleinen und großen Modelle, die verwendet wurden, weisen bei Datensatz 2 einen geringen Unterschied auf. Dieser führt zu einer geringen Verbesserung der Approximation.

Mit den in Kapitel 3.2 vorgestellten Methoden ist es gelungen, die Funktion der Aktoren mit ihrem Frequenzspektrum darzustellen. Dabei wurde der Einfluss verschiedener Parameter diskutiert und Veränderungen im zeitlichen Verlauf anhand der Chunks dargestellt. Es ergab sich ein deutlicher Unterschied in den Datensätzen, die auf einen Messfehler, einen Fehler im Prüfaufbau oder einen Fabrikationsfehler hinweisen. Die Reproduzierbarkeit des Versuchsaufbaus ist somit nicht gegeben. Anschließend ist die Approximation der Aktoren mittels der Fourierreihe durchgeführt und quantifiziert worden. Dieses Ergebnis ist vor allem bei der Produktlebensdauerbestimmung wichtig, da hiermit das weitere Verhalten der Aktoren prognostiziert werden kann. Eine Ungenauigkeit von bis zu 11% ist hierbei erreicht worden, wobei diese mittels komplexer und rechenintensiver Modelle erhöht werden kann.

5.3 Neuronale Netze

Eine weitere Möglichkeit zur Approximation der Lebensdauer von Produkten ist die Anwendung von Neuronalen Netzen zur Prognose des Datenverlaufes. Mittels dieser Methode wird die Funktion Daten berechnet und das Modell wird auf andere Datensätze angewendet. Diese werden zur Prognose von weiteren Daten angewendet und stellen eine Technologie zur Lebensdauerapproximation dar. Ähnlich wie im vorherigen Kapitel 3.2 wird der Datensatz aufgeteilt in einen Trainingsdatensatz und einen Testdatensatz zur Validierung, wobei mit dem gesamten Verlauf eines Aktors gelernt wird. Das Netz basiert auf den in Kapitel 3.6 vorgestellten Methoden und Strukturen. Die RELU wurde, aufgrund der genannten Vorteile, als Aktivierungsfunktion festgelegt. Das Gradientenoptimierungsverfahren ist ADABOOST. Das Netz ist wie in Tabelle 5.3 aufgebaut.

Tabelle 5.3: Beschreibung der Layer des Neuronalen Netzes

| Layer | Neuronen |
|------------------|----------|
| Input Layer | bis zu 4 |
| LSTM Layer - 1 | 128 |
| Dropout - 1 | 128 |
| LSTM Layer - 2 | 64 |
| Dropout - 2 | 64 |
| Dense Layer | 64 |
| Dropout - 3 | 64 |
| Time-Distributed | 5 |
| Output Layer | 1 |

Aufgrund der Periodizität der Zeitreihe werden 2 hintereinander geschaltete LSTM Layer eingesetzt, um die Informationen aus vorangegangenen Zeitschritten zu behalten. Diese Schichten sind mit einem Dropout versehen, um Overfitting zu verhindern. Anschließend wird ein reguläres Layer (Dense Layer) mit Dropout eingesetzt, um die Ergebnisse aus den LSTM-Modulen zu interpretieren. Zuletzt ergänzt die Time-Distributed Funktion ein Dense Layer für 5 Zeitschritte. Als Input können die Variablen Widerstand, Temperatur und Auslenkung verwendet werden und als Output prognostiziert das Netz die Zielvariable Auslenkung. In Abbildung 5.9 ist die Programmstruktur des Netzes visuell dargestellt.

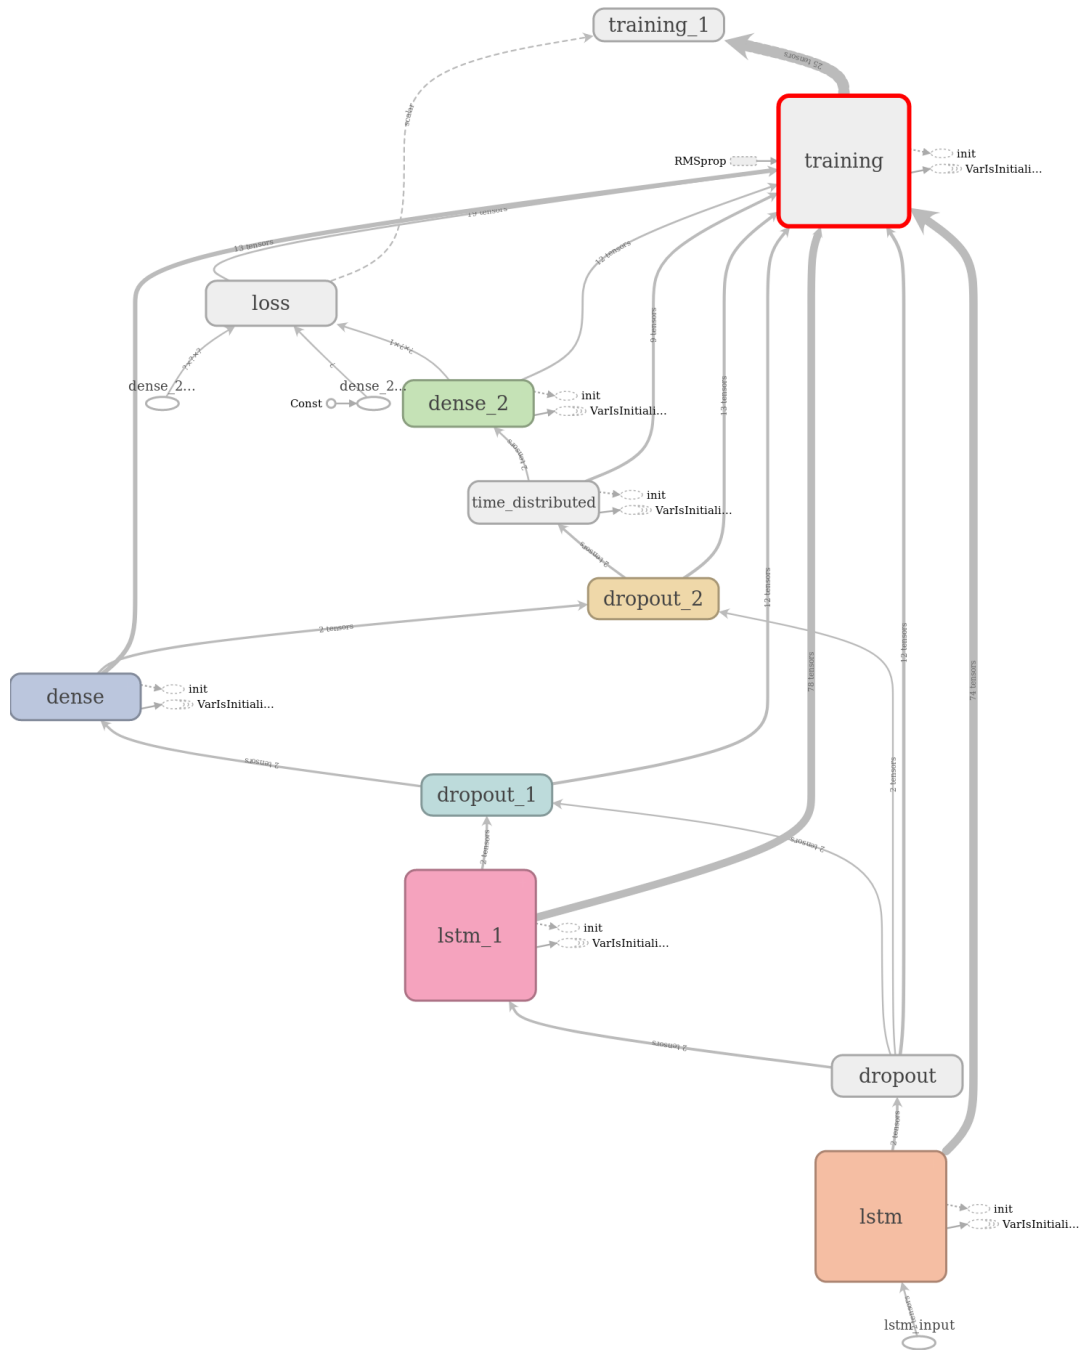


Abbildung 5.9: Aufbau des verwendeten Neuronalen Netzes: erstellt mit Tensorboard 1.13.1

Die Eigenschaft dieses Verfahrens, selbstständig einen Lernprozess nachzuahmen, wird ausgenutzt, um die Einflüsse der Kenngrößen zu untersuchen. Mit unterschiedlichen Inputvariablen werden die Netze trainiert und anschließend verglichen. Mit dieser Methode wird überprüft, ob dem maschinellen Algorithmus eigenständig Einflüsse auffallen und im Endergebnis wiedergefunden werden. Sollte die Eingabe unabhängig von dem zu bestimmenden Parameter sein, ist davon auszugehen, dass mittels der Gewichtungen der Neuronen diese eliminiert wird und der Output nicht beeinflusst wird.

Für jedes Netz wird der Datensatz in Trainings- und Testdatensätze aufgeteilt. Zum Validieren des Trainings werden 10% der Daten aus den Gesamtdaten verwendet, womit das Training mit 90% der Daten stattfindet. Eine weitere Annahme, die getroffen werden muss, ist, welche Daten verwendet werden. Folgende Optionen sind möglich:

- Datensatz 1
- Datensatz 2
- Datensatz 1 & 2

Aufgrund der langen Rechenzeit für das Trainieren des Netzes und der Unterschiede in der Datengrundlage, die in Kapitel 5.2 zu sehen sind, wird jeweils für beide Datensätze getrennt trainiert. Die Validierung ist im Vergleich zum Lernen weniger zeitintensiv und findet jeweils für beide Datensätze statt. Ein Netz wird mit 100 Zeitschritten und bis zu 10 Epochen gelernt und falls die Epochen nicht signifikant bessere Verbesserungen erzielen, wird der Lernprozess gestoppt. Die Lernrate, die die Anpassung der Gewichte nach jedem Zeitschritt festlegt, wird mit automatisierten Algorithmen nach jeder Epoche angepasst. Des Weiteren soll die Prognosequalität quantifiziert werden. Dies wird, mit der, in Kapitel 5.2 eingeführten, mittleren quadratischen Abweichung (MSE) durchgeführt.

Im weiteren Verlauf dieser Auswertung wird mit den Eingangsvariablen experimentiert und die Qualität der Prognose von unterschiedlichen Eingangsparametern verglichen. Da die direkte Abhängigkeit der Spannung und der Auslenkung bekannt ist, werden beide Parameter zum Lernen verwendet. Die Erwartung ist nach Kapitel 5.1, dass dies keinen Einfluss hat. Über die Zeit werden die Zyklen abgebildet. Diese stellen somit die Laufvariable der Zeitreihe dar. Das erste Netz wird anhand des ersten Datensatzes und der genannten Parametern trainiert, die Ergebnisse sind in folgender Tabelle dargestellt.

Tabelle 5.4: Ergebnisse des trainierten Neuronalen Netzes trainiert mit Datensatz 1 und den Variablen Spannung, Zeit und Auslenkung.

| Datensatz | Aktor | MSE |
|-----------|------------|--------|
| 1 | 1 | 0,0701 |
| 1 | 2 | 0,0560 |
| 1 | 3 | 0,0514 |
| 1 | 4 | 0,0705 |
| 1 | 5 | 0,0601 |
| 1 | 6 | 0,0452 |
| 1 | Mittelwert | 0,0588 |
| 2 | 1 | 0,0616 |
| 2 | 2 | 0,0384 |
| 2 | 3 | 0,0482 |
| 2 | 4 | 0,0799 |
| 2 | 5 | 0,0698 |
| 2 | 6 | 0,0762 |
| 2 | Mittelwert | 0,624 |

Der durchschnittliche Fehler bei Datensatz 1 liegt bei 0,0588 und bei Datensatz 2 bei 0,0624. Obwohl das Netz mit dem ersten Datensatz gelernt wurde, scheint der Unterschied der Prognose zu Datensatz 2 mit ca. 6% nicht groß zu sein. Der Verlauf beider Dauerbelastungen ist mit denselben Einstellungen aufgenommen worden, daher ist es zu erwarten, dass der Unterschied zwischen den Datensätzen nicht hoch ist.

Zur Überprüfung, ob Overfitting stattgefunden hat, werden die sog. Verluste (Abweichung von den Realdaten) der Epochen zeitlich aufgetragen. Bei diesem Effekt ist anzunehmen, dass die Lernrate nicht weiter angepasst wird und in jeder Epoche die selbe, oder eine sehr ähnliche, Funktion erreicht wird. In Abbildung 5.10 ist der Verlust eines Lernvorgangs in Bezug auf die Trainingsdaten eines Aktors dargestellt. Die zugehörige Graphik des Verlustes für die Validierung mit den Trainingsdaten ist in Anhang C dargestellt.




Abbildung 5.10: Epochenverlust eines Lerndurchlaufes; Validierung mit Testdaten

In der Graphik ist der Verlauf der Genauigkeit des trainierten Netzes zu erkennen. Die Lernrate ist mit den Startwerten anfangs ungeeignet gewählt, worauf diese angepasst wird und anschließend bessere Ergebnisse erzielt werden. Ein Anzeichen, dass Overfitting nicht stattgefunden hat, ist der schwankende Verlauf in dem MSE Wert. Zusätzlich ist das selbe Modell auf verschiedene Datensätze angewendet worden. Ein perfekt angepasstes Netz an den Trainingsdatensatz würde bei den anderen Aktorendaten schlechtere Prognosen erzielen. Wie aus den Tabellen 5.4-5.6 hervorgeht, liegt dies nicht vor. Eine qualitative Überprüfung, wie es in Kapitel 3.6 die Graphik 3.7 darstellt, wird auch hier angewandt. Die Testdaten (Blau) werden mit

den prognostizierten Werten (Orange) zusammen in der folgenden Abbildung 5.11 dargestellt.




Abbildung 5.11: Gegenüberstellung der realen Testdaten zur Prognose; Ausschnitt von $5 \cdot 10^4$ Daten; Testdaten (blau); Prognosewerte (orange).

Es ist ersichtlich, dass der grundlegende Verlauf (orange) der Daten vom Neuronalen Netz erkannt wird. Unregelmäßigkeiten, die auf ein Overfitting hinweisen, sind nicht zu erkennen. Die jeweiligen Peaks in der Messung werden vom Netz nicht explizit prognostiziert, womit die Auswertung im Allgemeinen auf andere, sich gleich verhaltende Datensätze übertragen werden kann. Sowohl die Ergebnisse, der Trainingsverlauf als auch die visuelle Überprüfung sprechen gegen ein Overfitting. Dieses wird daher ausgeschlossen und das Netz wird in seiner Auswertung als valide betrachtet.

Die Ergebnisse desselben Netzaufbaus werden im direkten Vergleich mit der anderen Datenbasis gestellt. Ein Aktor des zweiten Datensatzes wird zum Training verwendet. Zu erwarten ist, dass die Prognose durch den Datensatzunterschied abweicht. Die nachfolgende Tabelle 5.5 enthält die Ergebnisse der Validierung mit den Testdaten.

Tabelle 5.5: Ergebnisse des trainierten Neuronalen Netzes trainiert mit Datensatz 2 und den Variablen Spannung, Zeit und Auslenkung

| Datensatz | Aktor | MSE |
|-----------|------------|--------|
| 1 | 1 | 0,0704 |
| 1 | 2 | 0,0546 |
| 1 | 3 | 0,0501 |
| 1 | 4 | 0,0711 |
| 1 | 5 | 0,0588 |
| 1 | 6 | 0,0415 |
| 1 | Mittelwert | 0,0578 |
| 2 | 1 | 0,0656 |
| 2 | 2 | 0,0316 |
| 2 | 3 | 0,0474 |
| 2 | 4 | 0,0848 |
| 2 | 5 | 0,0718 |
| 2 | 6 | 0,0806 |
| 2 | Mittelwert | 0,0636 |

Der durchschnittliche Fehler bei Datensatz 1 liegt bei 0,0578 und bei Datensatz 2 bei 0,0636. Diese Ergebnisse sind fast identisch zu den Ergebnissen der vorherigen Prognose. Diesem Ergebnis nach enthält keiner der Trainingsdaten zusätzlichen Informationen, die das Ergebnis beeinflussen.

Die weiteren Netze sollen den Einfluss der verschiedenen Eingabeparameter überprüfen. Daher werden die folgenden Auswertungen auf Grundlage von Datensatz 2 gebildet. Auf die zusätzliche Analyse mit Datensatz 1 wird verzichtet aufgrund der Ähnlichkeit der Prognoseergebnisse. Die folgenden beiden Tabellen zeigen zwei Ergebnisse von Neuronalen Netzen. Bei dem Ersten wird zusätzlich die Temperatur in die Eingabeparameter aufgenommen. Das zweite Netz wird im Vergleich zu den vorherigen Netzen ohne die Spannung trainiert, es wird nur die Zeit und die Auslenkung verwendet.

Tabelle 5.6: Ergebnisse der Neuronalen Netze

- (a) trainiert mit Temperatur, Zeit, Spannung, Auslenkung
(b) trainiert mit Zeit und Auslenkung

(a) Neuronales Netz inklusive Temperatur. (b) Neuronales Netz exklusive Spannung.

| Datensatz | Aktor | MSE |
|-----------|------------|--------|
| 1 | 1 | 0,0713 |
| 1 | 2 | 0,0546 |
| 1 | 3 | 0,0500 |
| 1 | 4 | 0,0718 |
| 1 | 5 | 0,0587 |
| 1 | 6 | 0,0402 |
| 1 | Mittelwert | 0,0578 |
| 2 | 1 | 0,0663 |
| 2 | 2 | 0,0315 |
| 2 | 3 | 0,0472 |
| 2 | 4 | 0,0856 |
| 2 | 5 | 0,0723 |
| 2 | 6 | 0,0816 |
| 2 | Mittelwert | 0,0641 |

| Datensatz | Aktor | MSE |
|-----------|------------|--------|
| 1 | 1 | 0,0720 |
| 1 | 2 | 0,0547 |
| 1 | 3 | 0,0500 |
| 1 | 4 | 0,0721 |
| 1 | 5 | 0,0585 |
| 1 | 6 | 0,0394 |
| 1 | Mittelwert | 0,0578 |
| 2 | 1 | 0,0670 |
| 2 | 2 | 0,0258 |
| 2 | 3 | 0,0456 |
| 2 | 4 | 0,0870 |
| 2 | 5 | 0,0724 |
| 2 | 6 | 0,0829 |
| 2 | Mittelwert | 0,0635 |

Die Ergebnisse der Prognosen weisen im direkten Vergleich (Tabellen 5.4-5.6) keine Unterschiede in den verschiedenen Variablenkonstellationen auf. Das Neuronale Netz lernt keine zusätzlichen Informationen aus den Versuchen, ein Vergleich wird in der Tabelle 5.8 zu Veranschaulichung dargestellt.

Tabelle 5.8: Gegenüberstellung der Mittelwerte der mittleren quadratischen Abweichung von den verschiedenen gelernten Neuronalen Netzen. Trainingsgrundlage ist Datensatz 2.

| Variablen | gemittelter MSE Datensatz 1 | gemittelter MSE Datensatz 2 |
|---|--------------------------------|--------------------------------|
| Zeit, Spannung, Auslenkung | 0,0578 | 0,0636 |
| Zeit, Spannung, Auslenkung, Temperatur | 0,0578 | 0,0641 |
| Zeit, Auslenkung | 0,0578 | 0,0635 |

Mit dieser Methode ist es gelungen die Daten für Lebensdauerprognosen zu approximieren. Auffällig sind die identischen Mittelwerte der mittleren quadratischen Abweichung bei Datensatz 1 und sehr ähnliche Mittelwerte bei Datensatz 2, wenn die verschiedenen Inputvariablen verglichen werden. Daraus erfolgt, dass die veränderten Eingangsparameter irrelevant sind. Der einzige relevante Eingangsparameter ist, nach dieser Auswertung, die zu prognostizierende Auslenkung der Aktoren. Ein multivariater Einfluss ist aus der Analyse mit den Neuronalen Netzen nicht hervorgegangen. Die Vorhersage der Aktorendaten ist bei einer angenommen Auslenkung von 0,6 mm mit mit einer Abweichung von durchschnittlich 9,63% für Datensatz 1 und für 10,62% Datensatz 2 erfolgt. Eine Analyse über die Qualität des Netzes ist qualitativ durchgeführt worden. Das Netz führt kein Overfitting durch und prognostiziert die allgemeine Form der Daten (vgl. Abbildung 5.11). Das Ziel des Netzes, die Funktion der Aktorendaten zu bestimmen, ist erreicht worden.

5.4 Ergebnis

Dieses Unterkapitel fasst die Ergebnisse aus den vorherig angewandten Methoden zusammen und vergleicht diese miteinander. Anschließend wird ein Fehler des Prüfplatzes erläutert und die Folgen in der Auswertung diskutiert.

5.4.1 Zusammenfassung

Mittels der Autokorrelation ist es gelungen, das Verhalten der Parameter in einem zeitlichen Verlauf darzustellen. Die qualitative Analyse zeigt keine Zusammenhänge zwischen der Temperatur und der Auslenkung der Aktoren. Bei Datensatz 2 sind Fehleinflüsse durch die enthaltenen Ausfälle ersichtlich. Es folgt aus den Ergebnissen, dass sich die Funktion der Aktorenmessung über die Zeit verändert.

Die anschließende Fourier-Analyse beginnt mit der Analyse der Frequenzen. Über die Zeit dargestellt ergeben sich eindeutige Veränderungen von Datensatz 2. Dieses Verhalten ist ein Anzeichen für eine Degradation der Aktoren. Mittels der Standardabweichung des Spektrums wird dieses Verhalten quantifiziert und linear angefitet, der Test nach Wald und Wolfowitz bestätigt hierbei, dass kein zufälliger Verlauf vorliegt. Die Analyse des Spektrums wird mit der Prognose der Zeitreihe abgeschlossen. Hierbei werden die Fourierkoeffizienten und anschließend weitere Zeitschritte mit der Reihenformel 3.3 berechnet. Auch hier zeigt sich der Unterschied in den Datensätzen, die Güte der Prognose ist bei Datensatz 1 deutlich höher als bei Datensatz 2.

Die zweite angewandte Methode ist das Neuronale Netz. Dieses zeigt keine Einflüsse von unterschiedlichen Eingangsparametern. Die These, die in den vorherigen Analysen aufgestellt wurde, dass die aufgezeichneten Parameter keinen Einfluss auf die Auslenkung besitzen, wird mit dieser Auswertung unterstützt. Für das Netz stellt der Unterschied in den Daten, wie bei der Fourier-Analyse, keine Abweichung dar. Die Prognosen erzielen ähnlichen Ergebnissen, unabhängig von verschiedenen Variableneinflüssen.

Zum direkten Vergleich der Prognosen wird der durchschnittliche MSE der jeweiligen Methoden verwendet. Da bei dem Neuronalen Netz mehrere Parameter verwendet wurden, wird das einfachste Modell mit der Zeit und der Auslenkung als Eingabevariablen zum Vergleich verwendet. Die folgende Tabelle 5.9 stellt diese Ergebnisse als Überblick dar.

Tabelle 5.9: Gegenüberstellung der Ergebnisse der Methoden

| Variablen | gemittelter MSE Datensatz 1 | gemittelter MSE Datensatz 2 |
|-----------------|--------------------------------|--------------------------------|
| Neuronales Netz | $5,78 \cdot 10^{-2}$ | $6,35 \cdot 10^{-2}$ |
| Fourier-Analyse | $8,76 \cdot 10^{-5}$ | $6,43 \cdot 10^{-2}$ |

Der Vergleich zeigt bei der Anwendungen auf Datensatz keinen Unterschied. Dieser wird von beiden Methoden gleich gut prognostiziert. Für Datensatz 1, der sich gleichmäßiger verhält, ist die Prognose mit der Fourierreihe deutlich genauer. Das trainierte Netz erreicht mit der Anwendung eine Abstraktion der grundlegenden Funktion der Daten (vgl. 5.11). Die Schwankungen der einzelnen Maxima und regelmäßige Abweichungen werden von dem Neuronalen Netz nicht erfasst, eine entstehende Ungenauigkeit ist zu erwarten. Periodische Ungenauigkeiten können theoretisch mit dieser Methode erfasst werden, es ist aber vorzuziehen, diese aufgrund von Overfitting zu vernachlässigen. Fourierreihe können hingegen diese Einflüsse ohne Nachteile erfassen.

Zusammengefasst ist festzuhalten, dass die Fourierreihe für einzelne Datensätze die effektivere Methode zur Prognose der Lebensdauer ist. Die Fourierreihe muss für jeden Datensatz einzeln berechnet werden, womit die Transferleistung auf andere Daten schwierig ist. Das Neuronale Netz ist für diesen Transfer besser geeignet. Sind die Trainingsdaten ausreichend informativ, kann das trainierte Netz auf weitere Datensätze angewendet werden. Die benötigte Rechenleistung eines Netzes relativiert sich somit mit der Häufigkeit der Anwendung. Die Fourierreihe ist hingegen für jeden Datensatz anzuwenden.

Einflüsse der verschiedenen Messvariablen wurden mit den verschiedenen Methoden untersucht. Es sind keine multivariaten Einflüsse in den Aktorendaten feststellbar. Ein degradierender Einfluss ist bei Datensatz 2 nachgewiesen worden.

5.4.2 Korrektur des Prüfplatzes

Eine Untersuchung hat ergeben, dass der Unterschied zwischen den Datensätzen vermutlich aufgrund eines fehlerkonstruierten Bauteils auftritt. Diese Information ist kurz vor Abgabe dieser Thesis bekannt geworden und wird daher nachträglich in diesem Abschnitt diskutiert. Eine allgemeine Fehlerdiskussion zu den angewandten Methoden wird zusätzlich durchgeführt.

Eine Information, die in der Beschreibung des Prüfaufbaus nicht enthalten ist, ist der Anschlagstaster für die Aktorenauslenkung. Nach Anlegen der Spannung wird der Draht, durch die beschriebenen Effekte, zusammengezogen. Das verschiebbare Lager wird hierbei gegen den voreingestellten Taster gedrückt, der die Spannung ausschaltet. Die Messung wird also nicht, wie angenommen, über ein zeitlich definiertes Signal gesteuert. Es wird stattdessen ein Mechanismus verwendet. Die Abbildung 5.12 ergänzt den vorherigen Aktorenaufbau (Abbildung 2.2) mit dem Taster.




Abbildung 5.12: Prinzipskizze des Prüfplatzaufbaus mit Abstandstaster (rot) (Hess und Bracke 2019; modifiziert)

Dieser Taster ist auf eine definierte Höhe eingestellt und stellt somit im Idealfall eine periodische Messung dar. Der Taster ist auf einer Halterung angebracht, die über eine Schraube und ein Langloch mit der Prüfvorrichtung verbunden ist. Dieser

Aufbau ist ungeeignet für eine langfristige präzise Messung im Mikrometerbereich. Das bewegliche Lager trifft bei jedem Zyklus auf diesen Taster. Als Folge verschiebt sich dieser über viele Zyklen nach unten. Das Langloch bietet hierzu ausreichend Platz. Für die Messung bedeutet dies, dass der Aktor jeden Durchgang mit einer höheren Auslenkung durchführt.

Dieser Effekt ist in den Auswertungen von Datensatz 2 ersichtlich. In Abbildung 5.13 sind Daten im Endbereich der Messreihe von Datensatz 2 dargestellt.




Abbildung 5.13: Ausschnitt aus einem Zeitpunkt zum Ende der Messreihe (Datensatz 2) des Aktorenprüfplatzes

Im Vergleich mit den Anfängen des Datensatzes (vgl. Abbildung 2.3) sind deutliche Unterschiede zu erkennen. Die Auslenkung ist von 0,6mm auf über 0,8mm gestiegen. Durch die größere Strecke, die der Aktor zurücklegt, ist die Zeit zur Anlegung der Spannung gestiegen. In der Auswertung der Autokorrelation wurde bereits ein Einfluss der Spannung auf die Temperatur vermutet. Die erhöhte Temperatur von ca. 8 Grad Unterschied unterstützt diese These. Eine längere Erwärmungsphase führt zu einer höheren Temperatur des Prüfaufbaus. Zudem erklären sich die Ausfälle, die in Datensatz 2 aufgetreten sind: Die größere Auslenkung führt zu einer höhe-

ren Belastung des Materials. Der Draht muss sich entgegen der Federkraft weiter zusammenziehen und versagt.

Retrospektiv sind die Einflüsse von diesem Verhalten in den Auswertungen zu erkennen. Die Autokorrelationen zeigen eindeutige Einflüsse im zeitlichen Verlauf nach den genannten Lags (vgl. Kapitel 5.1), die zuvor mit den Ausfällen am Ende des Datensatzes begründet wurden, mit diesem Wissen ist der Einfluss des Tasters als wahrscheinlicher anzunehmen. Durch die längeren Spannungszyklen steigt die Temperatur stärker an. Dies ist in der Autokorrelation zu erkennen. Dieser Einfluss ist im Vergleich zur Auslenkung deutlich langsamer. Datensatz 1 weist hingegen diese Unterschiede nicht auf. Es ist deswegen anzunehmen, dass die Vorrichtung für diesen Versuch keine Fehlfunktion aufgewiesen hat. Das unruhige Verhalten, das im Spektrum beobachtet wurde (vgl. Kapitel 5.2), lässt sich mit der Verschiebung des Tasters oder der Lösung der Schraube erklären. Die unregelmäßigen Frequenzen sind durch Vibrationen o.Ä. zu begründen. Die aufgenommen Daten sind, wie die Unterschiede zeigen, nicht unter reproduzierbaren Verhältnissen aufgenommen worden und zur Analyse nur bedingt geeignet.

6 Ausblick

Zu Beginn dieses Kapitels sollen offene Fragen aus den vorangegangenen Kapiteln diskutiert werden. Anschließend werden zwei Konzepte vorgestellt die eine Erweiterung zu den in dieser Arbeit vorgestellten Methoden darstellen. Diese wurden aufgrund der geringen Datenlage oder des zeitlichen Aufwandes einer umfangreichen Implementierung nicht angewandt und werden als theoretisches Konzept vorgestellt.

6.1 angewandte Methodik

Die in Kapitel 5 angewendeten Methoden zeigen verschiedene Einflüsse der Messdaten auf und prognostizieren die Zeitreihen. Für ein weiteres Vorgehen und weitere Felder, die angewandt werden können, werden diese auf Hinblick auf weitere Auswertungsanwendungen diskutiert.

Im Allgemeinen lässt sich zur Auswertung sagen, dass die Daten aufgrund des Prüfplatzes nur bedingt geeignet sind. Eine Korrektur des Prüfaufbaus muss erfolgen und die Messungen müssen unter reproduzierbaren Bedingungen wiederholt werden. Die Versuchsbedingungen müssen zudem anders durchgeführt werden, da keine Degradation der Aktoren festgestellt werden konnte. Nach Buehler und Wang (1968) sind für manche FGL 10^7 Zyklen ohne Auswirkungen möglich. Eine solch hohe Zyklenzahl wird durch geringe Auslenkung und somit höheren Frequenzen der Aktorenmessung erzielt. Ein weitere Ansatz ist es, die Aktoren durch höhere Belastung zu einem schnelleren Materialverlust zu zwingen, wie es in Datensatz 2 geschehen ist.

Das Ergebnis der Autokorrelationsfunktionen ist eindeutig. Von der Verwendung der multivariate Anwendung wurde hierbei abgesehen. Dennoch ist diese nicht für zukünftige Anwendungen ausgeschlossen. Falls weitere Parameter aufgenommen werden und diese auf Kreuzkorrelationen überprüft werden sollen, ist dies ein Anwendungsfall, der mit dem vorgestellten Theorem durchgeführt werden kann.

Für die Spektralanalyse wurde in dieser Arbeit die Standardabweichung des Spektrums zur Bestimmung eines degradierenden Einflusses verwendet. Die einzelnen Frequenzen, die in Bereiche eingeteilt wurden, sind nicht interpretiert worden. Ein weiterer Schritt, der durchgeführt werden kann, ist die Ermittlung der Bedeutung

einzelner Frequenzanteile. Wie die Analysen ergeben haben, ist das Spektrum in ca. 5 Frequenzbereiche einzuteilen. Diese wurden auf Veränderungen überprüft. Um genaue Rückschlüsse ziehen zu können, ist es notwendig, die Bedeutung der Frequenzen zu verstehen. Wenn zurückverfolgt werden kann, welche Frequenzen zum Beispiel die Rückstellung der Aktoren darstellen, kann die Bestimmung der Degradation näher spezifiziert werden. Somit wird auch die Art der Degradation (vgl. Kapitel 2.2) bestimmt. Für dieses Vorgehen müssen entweder mehr Messparameter aufgenommen, diese aus den vorhandenen Daten extrahiert oder die Funktionen durch Frequenzfilter bearbeitet werden.

Die Neuronalen Netze weisen hierbei am meisten weitere Prognosepotential auf. Diese umfangreiche technologische Methode kann mit abgewandelten Layerstrukturen, Aktivierungsfunktionen oder Gradientenverfahren neu erprobt werden. Zudem ist eine Verknüpfung der Ergebnisse aus der Spektralanalyse möglich. Die Transformation in die komplexe Zahlenebene durch die Fouriertransformation wird in diesem Fall für die Inputs verwendet. Verschiedene Arbeiten wie *Associative Long Short-Term Memory* (Danihelka u. a. 2016), *Gated Orthogonal Recurrent Units: On Learning to Forget* (Jing u. a. 2019) oder *Neural-network-based motor rolling bearing fault diagnosis* (Li u. a. 2000) beschreiben Anwendungen in Bildverarbeitung oder LSTM Netzen, die auf komplexen Zahlen basieren. Im Vergleich erzielt das Netz mit komplexen Zahlen bessere Ergebnisse. Ein Ablaufdiagramm dieses Vorgehens wird von Li u. a. in Bezug auf Motorendaten dargestellt. Dieses ist in Abbildung 6.1 zu sehen.

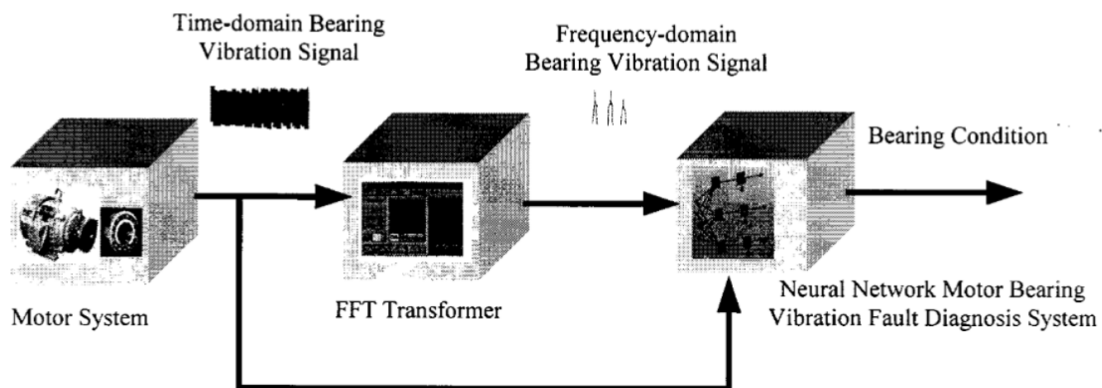


Abbildung 6.1: Ablaufdiagramm Ausfallprognose von Motorendaten mit Frequenzdaten (Li u. a. 2000).

Insbesondere bei Aufgaben mit Langzeiteffekten sind bessere Ergebnisse erzielt worden. Eine Implementierung eines solchen Netzwerkes ist am Beispiel der Aktoren zu untersuchen. Eine weitere Möglichkeit, die die Neuronalen Netze bieten, ist die Weiterverarbeitung der Prognosedaten. Wie in der Auswertung gezeigt wurde, erfasst das vorgestellte Modell die Grundfunktion der Daten. Diese kann, wie in Abbildung 5.11 dargestellt, als eine Glättung der Daten betrachtet werden. Mittels weiterer Verfahren oder erneuter Anwendung vorgestellter Methoden können diese Daten ohne Störeinflüsse untersucht werden. Eine Approximation der Degradation ist mit der Datenvorverarbeitung der Neuronalen Netze leichter durchzuführen.

Die vorgestellten Ansätze können auf die Aktorendaten oder auf allgemeine Zeitreihen, die sich ähnlich verhalten, angewandt werden. Ob diese zielführend ist, muss im Einzelfall erprobt werden.

6.2 Neuronales Netz zur Ausfallprediktion

Eine Ergänzung der Neuronalen Netze, die zur Produktlebensdaueranalyse beiträgt, ist es diese auf Ausfalldaten zu trainieren. Dies setzt voraus, dass eine Datengrundlage vorliegt, die mit ausreichend vielen Ausfallzeitpunkten versehen ist. Für die vorliegenden Aktorendaten trifft das nicht zu. Daher wird dieses Konzept als weiterführende Methode eingeführt.

Ein Neuronales Netz ist abstrakt formuliert ein Optimierungsmodell, das über trainierbare Entscheidungselemente verfügt. Die Fähigkeit zu optimieren wird für die Prognose des Ausfallzeitpunktes ausgenutzt. Mittels der Eingangsparameter ist es möglich, den wahrscheinlichsten Zeitpunkt zu ermitteln, sofern die Daten diese Information enthalten. Im Fall des Aktors bedeutet dies, dass durch die Auslenkung und die Zeit die Ausfallzeitpunkte bestimmt werden können. Je nach Verlauf der Variablen soll das Netz die Prognose anpassen. Gebraeel und Lawley (2008) beschreiben ein Vorgehen um diese Idee in einem ähnlichen Anwendungsfall von Lagern mit Degradation umzusetzen. Es werden Genauigkeiten der Prognose mit einem mittleren Fehler von 7,62% erzielt. Weitere Arbeiten wie *Fault prognosis using dynamic wavelet neural networks* (Vachtsevanos und Wang 2001) bestätigen die Wirksamkeit dieses Ansatzes.

6.3 Shazam Modell

Das Shazam Modell ist ein, in dieser Arbeit eingeführtes, Modell zur frühen Detektion von Ausfallmustern. Der Begriff "Shazam" steht im Amerikanischen für einen magischen Befehl oder einen Laut der Überraschung. International populär ist dieser durch die Applikation für Smartphones "Shazam" geworden, auf die sich das folgende Modell bezieht. Die Software der Firma Shazam Entertainment Limited, die seit 2018 zu Apple Inc. gehört, identifiziert Musik und Fernsehinhalte durch eine aufgenommene Audiospur. Dies funktioniert nach Firmenangaben in drei Schritten (vgl. *Shazam Entertainment Limited* 2019):

1. Eine Audioausschnitt wird vom Nutzer aufgenommen und an den Shazam Server übermittelt.
2. Über einen "digitalen Fingerabdruck" des Tonmaterials wird ein Vergleich mit der internen Datenbank durchgeführt. Diese beinhaltet Millionen von Songtiteln und TV-Shows.
3. Es erfolgt eine Rückmeldung an das Smartphone mit Informationen über das Werk, Autor o.Ä.

Dieses Vorgehen kann für technologische Anwendungen adaptiert werden. Jedes Bauteil unterliegt einer Produktlebensdauer, die über eine Ausfallverteilung, wie z.B. die Weibull-Verteilung beschrieben wird. Ein Rückschluss auf das individuelle Bauteil ist nicht möglich. Im Fall von Aktoren oder anderen periodisch agierenden Bauteilen ist es möglich, für diese eine Datenbank anzulegen, welche mit einem digitalen Fingerabdruck versehen sind. Anstelle von Tonmaterial können Messaufzeichnungen mit periodischem Charakter verwendet werden. In Kapitel 5.2 ist es gelungen, die Messreihe in Zeitabschnitte zu unterteilen und im Frequenzbereich mit den jeweiligen Frequenzen abzubilden. Der digitale Fingerabdruck von der Applikation wird über dasselbe Verfahren durchgeführt. Eine Audiospur wird eingegeben und von dem Zeitbereich in den Frequenzbereich transformiert, somit können die einzelnen Frequenzen der jeweiligen Lieder dargestellt werden. Der digitale Fingerabdruck entsteht durch anschließende Berechnung eines Hash¹ Wertes dieser Daten (vgl. Wang 2003). In der folgenden Abbildung 6.2 sind die Arbeitsschritte zur Erstellung des Hash Wertes abgebildet.

¹Eine Hashfunktion nimmt Zeichen oder Zahlen und ordnet diesen einen Wert bestimmter Länge zu, den Hash Wert (siehe Carter und Wegman 1979).

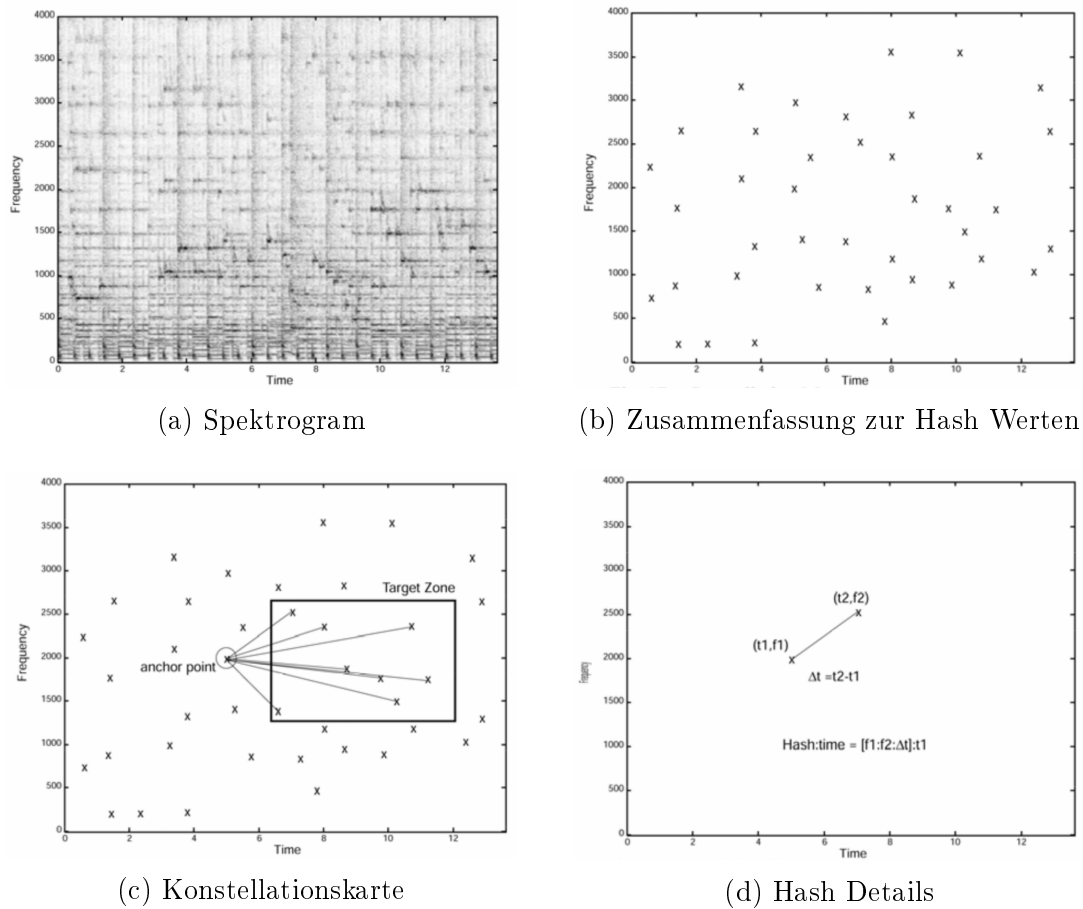


Abbildung 6.2: Visualisierte Arbeitsschritte zur Erstellung eines Hash Wertes aus einem Audiosignal (Wang 2003).

Der Hashwert wird nach Wang (2003) in drei Schritten berechnet:

1. Berechnung der Frequenzen (Abbildung 6.2a)
2. Reduzierung des Spektrograms zu eindeutigen Koordinaten (Abbildung 6.2b)
3. Bestimmung des Hash Wertes. Dies wird umgesetzt, indem Ankerpunkte bestimmt und mit einer jeweiligen Zielzone verknüpft werden (Abbildung 6.2c). Jedes daraus resultierende Punktpaar beinhalten zwei Frequenzkomponenten und die Zeitdifferenz. Sie stellen die Eingabewerte für die Hashfunktion dar (Abbildung 6.2d).

Jeder Hash Wert wird zusätzlich mit relativen Zeitpunkten versehen. Daraus entsteht für ein Lied eine Liste von Hash Werten. Der Transfer des Verfahrens kann auf Bauteile wie Motoren, die im Feld laufend Daten aufzeichnen, getätigt werden. Liegt zum Beispiel eine Datenbank mit Fingerabdrücken von unterschiedlich ausgefallenen Motoren vor, können Felddaten mit dieser Datenbank verglichen werden. Das Ergebnis dieses Vorgehens ist, wie bei der Audio Eingabe, die Rückgabe des Motors, der die größte Übereinstimmung mit dem Fingerabdruck besitzt. Der Vorteil ist hierbei, dass im Gegensatz zu anderen Verfahren keine individuellen Bauteile mit Flotten betrachtet werden, sondern ein individuelles Nutzungsverhalten mit Anderen zu jedem Zeitpunkt verglichen werden kann. Sind in der Datenbank Ausfallzeitpunkte hinterlegt, so kann der Ausfallzeitpunkt mittels der Abweichung des Fingerabdrucks prognostiziert werden.

Ein wichtiger Aspekt der Applikation ist die Filterung der Liedspur von Stör- und Umgebungsgeräuschen. In der technologischen Anwendung ist zu betrachten, wie einflussreich Störungen im Feld sind. Werden die Daten in gleichbleibendem Umfeld verwendet, ist eine Filterung überflüssig. Sind Abweichungen zu erwarten, so können Filtermaßnahmen durchgeführt werden.

Der Abgleich der Fingerabdrücke wird in Abbildung 6.3 dargestellt. Alle Hashes des einzulesenden Audiofiles werden mit der Datenbank verglichen. Die relativen Zeitwerte des Hashes werden mit denen der Datenbank verglichen. Liegt eine Ähnlichkeit der Hashes zu einem bestimmten Zeitpunkt vor, ergibt sich ein Offset. Durch die Verschiebung wird eine Diagonale sichtbar. Ein effizienter Algorithmus wird in der Veröffentlichung *An industrial-strength audio search algorithm* (Wang 2003) präsentiert.




Abbildung 6.3: Abgleich eines Audio-Mitschnittes mit der Datenbank (Wang 2003)

Der Vorteil dieser Methode ist, dass Individuen Bauteilen zugeordnet werden können, die sich gleich verhalten. Dies erschließt die Möglichkeit für Einzelne die Lebensdauer und den Ausfallzeitpunkt zu bestimmen. Nach Wang ist der Algorithmus zeiteffizient. Die Geschwindigkeit aus einem Beispieldatensatz von 20.000 Liedern in

der Datenbank benötigte 2003 eine Berechnungszeit von 5-500 Millisekunden, welche Rechenzeit bei Felddaten von Produkten moderner Technik entstehen, muss erprobt werden. Zusätzlich ist dieses Verfahren für Produkte im Feld geeignet, da geringe Daten übertragen werden müssen und die Berechnung auf einem Server stattfindet. Werkstätten oder Geräte mit Übertragungstechnologien können eigenständig Anfragen zur Lebensdauer durchführen. Der Nachteil besteht in der vorausgesetzten Datenbank. Um die digitalen Fingerabdrücke zu vergleichen, müssen Vergleichsdaten vorher angelegt werden. Bei Produkten mit geringer Stückzahl ist es nicht möglich, die Datenbank aufzubauen. Existiert die Grundlage, können Felddaten jederzeit zur Datenbank hinzugefügt werden. Somit ist es möglich die Prognosen genauer zu gestalten.

7 Zusammenfassung

In dieser Arbeit werden verschiedene Methoden zur Approximation der Produktlebensdauer vorgestellt und anschließend am Beispiel von Aktoren mit Formgedächtnislegierung angewendet. Die Aktorenteknologie sowie der Prüfstand zur Erhebung der Daten werden zu Beginn eingeführt. Das Ziel des Prüfaufbaus ist es, degradierende Einflüsse durch Feldsimulation zu simulieren. Verschiedene Effekte von Degradation bei Formgedächtnislegierungen werden erläutert.

Die aufgezeichneten Daten können als Zeitserie betrachtet werden, womit das Themengebiet dieser Arbeit sich primär darauf einschränkt. Vorgestellt werden Methoden aus verschiedenen Wissenschaften wie das Box-Jenkins Modell, die Fourier-Analyse, die Regressionsanalyse oder Neuronale Netze. Es erfolgt eine Einführung der Autokorrelationsfunktion mit dem Wiener-Khintchin Theorem zur Analyse der Daten. Die Vorstellung der Methoden nimmt Bezug auf multivariate Varianten und deren Umsetzung. Durch multiple erfasste Einflussgrößen ist es möglich auf die degradierenden Eigenschaften zu testen.

Die vorgestellten Methoden werden für die Anwendung auf die vorliegenden Aktorendaten diskutiert und bewertet. Ein Ausschlusskriterium ist eine lange Berechnungsdauer der Methode durch die große Datenanzahl. Methoden, die eine Datenverdichtung benötigen werden auch ausgeschlossen, weil die Degradation in allen Phasen der Messung auftreten kann und somit müssen alle Daten verwendet werden. Es wird eine Analyse mittels der Autokorrelationen der Datensätze durchgeführt. Die erstellten Korellogramme zeigen Zusammenhänge zwischen den Einflussgrößen und die Messdaten nach kurzer Zeit mit sich selber nicht mehr korrelieren.

Eine Durchführung der Fourier-Analyse findet im Anschluss an die Autokorrelationsdiagramme statt. Mit dieser wird anhand der Aktoren gezeigt, wie frequenzielle Einflüsse über die Zeit erkannt werden können. Diese Veränderungen werden in Hinblick auf Degradation und multivariaten Einflussmerkmalen diskutiert. Es zeigt sich, dass sich die vorliegenden Daten für die Prognose unterschiedlich verhalten und für eine Analyse nur bedingt geeignet sind. Die Durchführung der Fourierreihe stellt eine Methode zur Prognose zur Unterstützung der Approximation von der Produktlebensdauer dar. Die Abweichung der Prognosedaten zu den Realdaten liegt bei einem Datensatz (Datensatz 1) durchschnittlich bei 0,015% und für den zweiten getesteten Datensatz (Datensatz 2) bei 10,72%.

Das zweite Prognosemodell, dass in dieser Arbeit Anwendung findet, ist das Neuronale Netz. Dieses ist eine Methode der künstlichen Intelligenz und soll anhand der Eingabeparameter die theoretische Funktion der Eingangsdaten nachbilden, um eine Zielvariable zu prognostizieren. Die Ergebnisse zur Prognose des Aktorendatensatzes weisen Ähnlichkeiten zur Auswertung der Fourierreihe auf. Mit einem durchschnittlichen Fehler von 10,62% ist die Prognose von Datensatz 2 nahezu identisch. Ein signifikant anderes Ergebnis erzielt das angewandte Neuronale Netz bei Datensatz 1 mit durchschnittlich 9,63% Abweichung von den Realdaten. Für die Bestimmung der Einflüsse verschiedener aufgenommener Parameter wird die Methode mit verschiedener Eingangsvariablen trainiert. Ein Unterschied zwischen den Ergebnissen der Netze mit unterschiedlichen Eingabevariablen tritt dabei nicht auf. Der Einfluss von multivariaten Merkmalen ist nicht nachzuweisen.

Abschließend werden weiterführende Maßnahmen und Methoden vorgestellt, die auf gleiche Aufgabenstellungen angewandt werden können. Die Methode der Neuronalen Netze wird weiter ausgeführt und ein Modell, das auf der Applikation "Shazam" basiert, ist vorgestellt worden. Dieses basiert auf den vorgestellten Methoden. Mittels des Ausblicks eröffnen sich weitere Forschungsfelder und Implementierungsmaßnahmen.

Die für diese Arbeit formulierten Ziele sind vollständig erreicht. Die Anwendung von verschiedenen Methoden anhand der Aktorendaten wurde durchgeführt. Diese sind erfolgreich im Frequenzspektrum dargestellt und für die Produktlebensdauer prognostiziert. Multivariate Einflussgrößen sind untersucht und nicht in den Realdaten beobachtet worden.

Es wird ein Überblick über die Thematik der Zeitreihenanalyse verschafft und diese wird angewendet. Diese Arbeit stellt erfolgreich durch die vielfältig vorgestellten Methoden einen Überblick zur Produktlebensdauerbestimmung auf Basis des Degradationsverhaltens dar. Ein ideales Modell für Lebensdauerapproximation wird nicht eingeführt, da dieses von vielen Einflüssen wie der Datenlage und den Anforderungen an die Auswertung (z.B. Wirtschaftlichkeit) abhängig ist. Es lässt sich aber hierzu festhalten:

Das ideale Modell zur Lebensdauerapproximation ist jenes, das individuell an die Datenlage angepasst ist.

I Abkürzungsverzeichnis

ACF auto correlation function - Autokorrelationsfunktion

USL upper specification limit - obere Spezifikationsgrenze

LSL lower specification limit - untere Spezifikationsgrenze

FGL Formgedächtnislegierung

RELU rectifier linear unit - Gleichrichter Aktivierungsfunktion

FFT fast fourier transform - Schnelle Fouriertransformation

MSE mean squared error - mittlere quadratische Abweichung

LSTM long short term memory - langes Kurzzeitgedächtnis

ARIMA autoregressive integrated moving average - autoregressiver integrierter
gleitender Durchschnitt

ARMA autoregressive moving average - autoregressiver gleitender Durchschnitt

SARIMA seasonal autoregressive integrated moving average - autoregressiver
integrierter gleitender Durchschnitt mit saisonaler Abhängigkeit

VAR Vektor Autoregression

OLS ordinary least square - gewöhnliche kleinste Quadrate

II Anhang

A Korrelationsdiagramme




Abbildung A.1: Autokorrelation der Messreihe des ersten Datensatzes: Auslenkung von Akteur 1.




Abbildung A.2: Autokorrelation der Messreihe des ersten Datensatzes: Temperatur.




Abbildung A.3: Autokorrelation der Messreihe des ersten Datensatzes: Widerstand.

B Ergebnis der linearen Regression

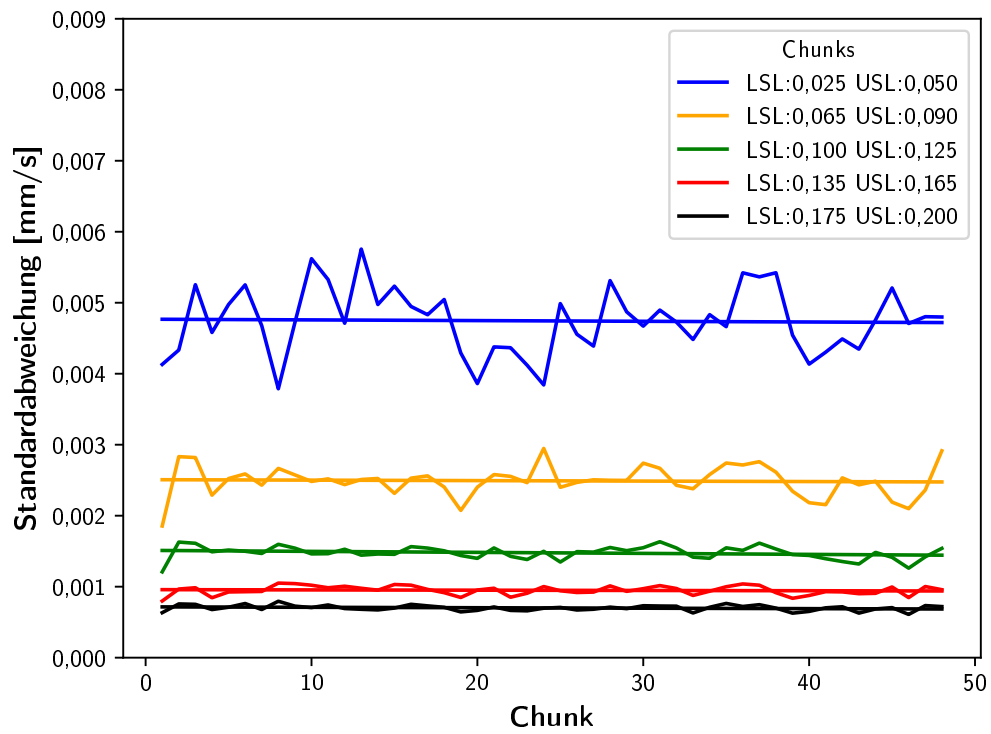


Abbildung B.4: Standardabweichungen des Spektrums, zeitlicher Verlauf durch Chunks dargestellt: Datensatz 1.

Tabelle B.1: Werte der Regressionsanalyse der Standardabweichung des Aktorespektrums (Datensatz 1) mit der Formel $y(x) = a \cdot x + b$, sowie dem p-value des einseitigen Wald-Wolfowitz Runs-Test (Wald und Wolfowitz 1940)

| Datensatz | Aktor | Variable | 0,025-0,050 Hz | 0,065-0,090 Hz | 0,010-0,125 Hz | 0,135 - 0,165 Hz | 0,175 - 0,200 Hz |
|-----------|-------|----------|-----------------------|-----------------------|-----------------------|-----------------------|-----------------------|
| 1 | 1 | r^2 | $0,89 \cdot 10^{-3}$ | $0,19 \cdot 10^{-2}$ | $0,49 \cdot 10^{-1}$ | $0,81 \cdot 10^{-2}$ | $0,04 \cdot 10^{-2}$ |
| 1 | 1 | a | $-0,98 \cdot 10^{-6}$ | $-0,67 \cdot 10^{-6}$ | $-0,14 \cdot 10^{-5}$ | $-0,39 \cdot 10^{-6}$ | $0,63 \cdot 10^{-6}$ |
| 1 | 1 | b | $0,048 \cdot 10^{-2}$ | $0,25 \cdot 10^{-2}$ | $0,15 \cdot 10^{-2}$ | $0,96 \cdot 10^{-3}$ | $0,72 \cdot 10^{-3}$ |
| 1 | 1 | p-value | 0,47 | 0,92 | 0,20 | 0,06 | 0,92 |
| 1 | 2 | r^2 | $0,11 \cdot 10^{-1}$ | $0,98 \cdot 10^{-2}$ | $0,81 \cdot 10^{-3}$ | $0,98 \cdot 10^{-3}$ | $0,251 \cdot 10^{-2}$ |
| 1 | 2 | a | $0,19 \cdot 10^{-4}$ | $0,11 \cdot 10^{-4}$ | $0,21 \cdot 10^{-5}$ | $-0,12 \cdot 10^{-5}$ | $0,12 \cdot 10^{-5}$ |
| 1 | 2 | b | $0,27 \cdot 10^{-1}$ | $0,26 \cdot 10^{-1}$ | $0,23 \cdot 10^{-1}$ | $0,17 \cdot 10^{-1}$ | $0,13 \cdot 10^{-1}$ |
| 1 | 2 | p-value | 0,49 | 0,49 | 0,20 | 0,89 | 0,84 |
| 1 | 3 | r^2 | $0,85 \cdot 10^{-3}$ | $0,46 \cdot 10^{-2}$ | $0,52 \cdot 10^{-3}$ | $0,11 \cdot 10^2$ | $0,90 \cdot 10^{-3}$ |
| 1 | 3 | a | $-0,74 \cdot 10^{-2}$ | $-0,72 \cdot 10^{-2}$ | $0,18 \cdot 10^{-2}$ | $-0,19 \cdot 10^{-2}$ | $-0,14 \cdot 10^{-2}$ |
| 1 | 3 | b | 4,67 | 2,14 | 1,43 | 1,10 | 0,85 |
| 1 | 3 | p-value | 0,73 | 0,73 | 0,73 | 0,73 | 0,73 |
| 1 | 4 | r^2 | $0,10 \cdot 10^{-4}$ | $0,38 \cdot 10^{-1}$ | $0,48 \cdot 10^{-1}$ | $0,26 \cdot 10^{-2}$ | $0,47 \cdot 10^{-2}$ |
| 1 | 4 | a | $0,99 \cdot 10^{-7}$ | $-0,23 \cdot 10^{-5}$ | $0,15 \cdot 10^{-5}$ | $-0,55 \cdot 10^{-6}$ | $-0,57 \cdot 10^{-6}$ |
| 1 | 4 | b | $0,46 \cdot 10^{-2}$ | $0,25 \cdot 10^{-2}$ | $0,15 \cdot 10^{-2}$ | $0,92 \cdot 10^{-3}$ | $0,71 \cdot 10^{-3}$ |
| 1 | 4 | p-value | 0,24 | 0,92 | 0,07 | 0,47 | 0,6 |
| 1 | 5 | r^2 | $0,58 \cdot 10^{-2}$ | 0,00 | $0,29 \cdot 10^{-3}$ | $0,026 \cdot 10^{-1}$ | $0,48 \cdot 10^{-2}$ |
| 1 | 5 | a | $-0,28 \cdot 10^{-5}$ | $-0,23 \cdot 10^{-7}$ | $-0,12 \cdot 10^{-6}$ | $-0,65 \cdot 10^{-6}$ | $-0,16 \cdot 10^{-6}$ |
| 1 | 5 | b | $0,41 \cdot 10^{-2}$ | $0,21 \cdot 10^{-2}$ | $0,14 \cdot 10^{-2}$ | $0,90 \cdot 10^{-3}$ | $0,67 \cdot 10^{-3}$ |
| 1 | 5 | p-value | 0,66 | 0,67 | 0,74 | 0,20 | 0,19 |
| 1 | 6 | r^2 | $0,28 \cdot 10^{-2}$ | $0,45 \cdot 10^{-2}$ | $0,48 \cdot 10^{-1}$ | $0,28 \cdot 10^{-2}$ | $0,35 \cdot 10^{-2}$ |
| 1 | 6 | a | $-0,19 \cdot 10^{-5}$ | $-0,78 \cdot 10^{-6}$ | $-0,98 \cdot 10^{-6}$ | $-0,43 \cdot 10^{-6}$ | $-0,12 \cdot 10^{-6}$ |
| 1 | 6 | b | $0,40 \cdot 10^{-2}$ | $0,21 \cdot 10^{-2}$ | $0,14 \cdot 10^{-2}$ | $0,87 \cdot 10^{-3}$ | $0,68 \cdot 10^{-3}$ |
| 1 | 6 | p-value | 0,22 | 0,25 | 0,92 | 0,06 | 0,19 |

C Epochen Verlust Validierung




Abbildung B.5: Epochen Verlust eines Lerndurchlaufes: Validierung mit Trainingsdaten

Tabelle B.2: Werte der Regressionsanalyse der Standardabweichung des Aktorespektrums (Datensatz 2) mit der Formel $y(x) = a \cdot x + b$, sowie dem p-value des einseitigen Wald-Wolfowitz Runs-Test (Wald und Wolfowitz 1940)

| Datensatz | Aktor | Variable | 0,025-0,050 Hz | 0,065-0,090 Hz | 0,100-0,125 Hz | 0,135 - 0,165 Hz | 0,175 - 0,200 Hz |
|-----------|-------|----------|-----------------------|-----------------------|-----------------------|-----------------------|-----------------------|
| 2 | 1 | r^2 | 0,73 | 0,45 | 0,49 | 0,69 | 0,62 |
| 2 | 1 | a | $0,34 \cdot 10^{-4}$ | $0,11 \cdot 10^{-5}$ | $0,49 \cdot 10^{-6}$ | $0,43 \cdot 10^{-6}$ | $0,29 \cdot 10^{-6}$ |
| 2 | 1 | b | $0,51 \cdot 10^{-2}$ | $0,27 \cdot 10^{-2}$ | $0,17 \cdot 10^{-2}$ | $0,10 \cdot 10^{-2}$ | $0,77 \cdot 10^{-3}$ |
| 2 | 1 | p-value | $0,15 \cdot 10^{-7}$ | $0,22 \cdot 10^{-4}$ | $0,28 \cdot 10^{-5}$ | $0,15 \cdot 10^{-7}$ | $0,15 \cdot 10^{-7}$ |
| 2 | 2 | r^2 | 0,10 | 0,27 | 0,27 | 0,27 | 0,18 |
| 2 | 2 | a | $-0,55 \cdot 10^{-5}$ | $-0,48 \cdot 10^{-5}$ | $-0,25 \cdot 10^{-5}$ | $-0,14 \cdot 10^{-4}$ | $-0,13 \cdot 10^{-4}$ |
| 2 | 2 | b | $0,63 \cdot 10^{-2}$ | $0,40 \cdot 10^{-2}$ | $0,20 \cdot 10^{-2}$ | $0,13 \cdot 10^{-2}$ | $0,11 \cdot 10^{-2}$ |
| 2 | 2 | p-value | $0,39 \cdot 10^{-9}$ | $0,25 \cdot 10^{-10}$ | $0,25 \cdot 10^{-11}$ | $0,78 \cdot 10^{-11}$ | $0,25 \cdot 10^{-11}$ |
| 2 | 3 | r^2 | 0,84 | 0,73 | 0,92 | 0,85 | 0,86 |
| 2 | 3 | a | $0,60 \cdot 10^{-4}$ | $0,12 \cdot 10^{-4}$ | $0,12 \cdot 10^{-4}$ | $0,61 \cdot 10^{-5}$ | $0,59 \cdot 10^{-5}$ |
| 2 | 3 | b | $0,47 \cdot 10^{-2}$ | $0,27 \cdot 10^{-2}$ | $0,15 \cdot 10^{-2}$ | $0,10 \cdot 10^{-2}$ | $0,76 \cdot 10^{-3}$ |
| 2 | 3 | p-value | $0,32 \cdot 10^{-3}$ | $0,14 \cdot 10^{-1}$ | $0,23 \cdot 10^{-6}$ | $0,40 \cdot 10^{-6}$ | $0,77 \cdot 10^{-8}$ |
| 2 | 4 | r^2 | 0,84 | 0,84 | 0,76 | 0,83 | 0,81 |
| 2 | 4 | a | $0,51 \cdot 10^{-4}$ | $0,19 \cdot 10^{-4}$ | $0,98 \cdot 10^{-5}$ | $0,66 \cdot 10^{-5}$ | $0,48 \cdot 10^{-5}$ |
| 2 | 4 | b | $0,46 \cdot 10^{-2}$ | $0,24 \cdot 10^{-2}$ | $0,14 \cdot 10^{-2}$ | $0,89 \cdot 10^{-3}$ | $0,68 \cdot 10^{-3}$ |
| 2 | 4 | p-value | $0,71 \cdot 10^{-9}$ | $0,24 \cdot 10^{-10}$ | $0,17 \cdot 10^{-6}$ | $0,54 \cdot 10^{-12}$ | $0,52 \cdot 10^{-12}$ |
| 2 | 5 | r^2 | 0,87 | 0,75 | 0,89 | 0,82 | 0,86 |
| 2 | 5 | a | $0,6 \cdot 10^{-4}$ | $0,17 \cdot 10^{-4}$ | $0,12 \cdot 10^{-4}$ | $0,72 \cdot 10^{-5}$ | $0,55 \cdot 10^{-5}$ |
| 2 | 5 | b | $0,45 \cdot 10^{-2}$ | $0,27 \cdot 10^{-2}$ | $0,15 \cdot 10^{-2}$ | $0,10 \cdot 10^{-2}$ | $0,7 \cdot 10^{-3}$ |
| 2 | 5 | p-value | $0,52 \cdot 10^{-12}$ | $0,26 \cdot 10^{-3}$ | $0,17 \cdot 10^{-7}$ | $0,25 \cdot 10^{-6}$ | $0,32 \cdot 10^{-3}$ |
| 2 | 6 | r^2 | 0,72 | 0,79 | 0,68 | 0,79 | 0,70 |
| 2 | 6 | a | $0,39 \cdot 10^{-4}$ | $0,15 \cdot 10^{-4}$ | $0,59 \cdot 10^{-5}$ | $0,60 \cdot 10^{-5}$ | $0,42 \cdot 10^{-5}$ |
| 2 | 6 | b | $0,46 \cdot 10^{-2}$ | $0,24 \cdot 10^{-2}$ | $0,15 \cdot 10^{-2}$ | $0,90 \cdot 10^{-3}$ | $0,72 \cdot 10^{-3}$ |
| 2 | 6 | p-value | $0,15 \cdot 10^{-7}$ | $0,17 \cdot 10^{-7}$ | $0,27 \cdot 10^{-3}$ | $0,98 \cdot 10^{-9}$ | $0,14 \cdot 10^{-8}$ |

Literatur

- Box, G. E. P., und G. C. Tiao. 1975. Intervention Analysis with Applications to Economic and Environmental Problems. *Journal of the American Statistical Association* 70 (349): 70.
- Box, George Edward Pelham, u. a. 1976. *Time series analysis: forecasting and control*. Wiley.
- Brandt, Patrick T., und John T. Williams. 2007. *Multiple time series models*. Sage Publications.
- Buehler, William J., und Frederick E. Wang. 1968. A summary of recent research on the nitinol alloys and their potential application in ocean engineering. *Ocean Engineering* 1 (1): 105–120.
- Carter, J. Lawrence, und Mark N. Wegman. 1979. Universal classes of hash functions. *Journal of Computer and System Sciences* 18 (2): 143–154. ISSN: 0022-0000.
- Chabacano. 2008. *Overfitting*. Wikimedia Commons. <https://commons.wikimedia.org/wiki/File:Overfitting.svg>.
- Chen, Z., und S. Zheng. 2005. Lifetime Distribution Based Degradation Analysis. *IEEE Transactions on Reliability* 54 (1): 3–10.
- Chevalier, Guillaume. 2018. *The LSTM cell*. Abgerufen am: 2019-05-11. https://commons.wikimedia.org/wiki/File:The_LSTM_cell.png.
- Cleveland, Robert B., William S. Cleveland und Irma Terpenning. 1990. STL: A Seasonal-Trend Decomposition Procedure Based on Loess. *Journal of Official Statistics* 6 (1): 3.
- Coffin, L. F. 1953. *A study of the effects of cyclic thermal stresses on a ductile metal*. Knolls Atomic Power Laboratory.
- Cohen, L. 1998. The generalization of the Wiener-Khinchin theorem. In *Proceedings of the 1998 IEEE International Conference on Acoustics, Speech and Signal Processing, ICASSP '98 (Cat. No.98CH36181)*, 3:1577–1580. IEEE. ISBN: 0-7803-4428-6.
- Cooley, James W., und John W. Tukey. 1965. An Algorithm for the Machine Calculation of Complex Fourier Series. *Mathematics of Computation* 19 (90): 297.
- Cryer, Jonathan D., und Kung-sik Chan. 2011. *Time series analysis: with applications in R*. Springer.

- Danihelka, Ivo, u. a. 2016. Associative Long Short-Term Memory. *CoRR* abs/1602.03032. arXiv: 1602.03032.
- Davenport, Thomas H., und D. J. Patil. 2012. Data Scientist: The Sexiest Job of the 21st Century. Abgerufen am: 2019-05-29, *Harvard Business Review* (Oktober). https://perso.esiee.fr/~bercherj/Documents/data/Harvard_Data-Scientist-The-sexiest-job-of-the-21st-century_2012.pdf.
- Dickey, David A., und Wayne A. Fuller. 1979. Distribution of the Estimators for Autoregressive Time Series with a Unit Root. *Journal of the American Statistical Association* 74 (366a): 427–431.
- Enders, Walter. 2015. *Applied economic time series*. Wiley.
- Engelmann, Sven, Jan Meyer und Reinhard Hentschke. 2017. Computer simulation of thermal conductivity in vulcanized polyisoprene at variable strain and temperature. *Physical Review B* 96 (5). ISSN: 2469-9950.
- Engeln-Müllges, Gisela, und Frank Uhlig. 1996. Two-Dimensional Splines, Surface Splines, Bézier Splines, B-Splines. *Numerical Algorithms with C*: 299–339.
- Facebook Inc. 2017. *Prophet*. Github Repository, abgerufen am 27.05.2019. <https://github.com/facebook/prophet>.
- Gasquet, Claude, Patrick Witomski und R. Ryan. 1999. *Fourier analysis and applications: filtering, numerical computation, wavelets*. Springer Verlage.
- Gebhard, Kirchgässner, und Wolters Jürgen. 2006. *Einführung in die moderne Zeitreihenanalyse*. Vahlen.
- Gebraeel, Nagi Z., und Mark A. Lawley. 2008. A Neural Network Degradation Model for Computing and Updating Residual Life Distributions. *IEEE Transactions on Automation Science and Engineering* 5 (1): 154–163.
- Girod, Bernd, Rudolf Rabenstein und Alexander Stenger. 2003. *Einführung in die Systemtheorie: Signale und Systeme in der Elektrotechnik und Informationstechnik*. Teubner.
- Glosser.ca, Wikimedia. 2013. *Colored neural network*. Abgerufen am: 2019-05-28. Wikimedia Commons. https://commons.wikimedia.org/wiki/File:Colored_neural_network.svg.
- Grossberg, Stephen. 1989. *Neural networks and natural intelligence*. MIT Press.
- Hamilton, J. D. 1994. *Time series analysis*. Princeton University.
- Hess, Philip, und Stefan Bracke. 2019. Reliability and degradation analysis of smart material actuators. Im Druck, *European Safety and Reliability Conference*.

- Heß, Philipp, und Stefan Bracke. 2018. Zuverlässigkeitstechnik bei Formgedächtnisaktoren: Entwicklung von Prüfstandstechnik und Erprobungsprogramm. Im Druck, *Gesellschaft für Qualitätswissenschaft e.V.*
- Hinton, Geoffrey E., u. a. 2012. Improving neural networks by preventing co-adaptation of feature detectors. *CoRR* abs/1207.0580. arXiv: 1207.0580. <http://arxiv.org/abs/1207.0580>.
- Hochreiter, Sepp, und Jürgen Schmidhuber. 1997. Long Short-Term Memory. *Neural Computation* 9 (8): 1735–1780. ISSN: 0899-7667.
- Humbeeck, J. Van. 1991. Cycling Effects, Fatigue And Degradation Of Shape Memory Alloys. *Le Journal de Physique IV* 01 (C4).
- Janocha, Hartmut. 2010. *Unkonventionelle Aktoren*. Oldenbourg Wissenschaftsverlag.
- Jing, Li, u. a. 2019. Gated Orthogonal Recurrent Units: On Learning to Forget. *Neural Computation* 31 (4): 765–783.
- Jürgen, Vogel. 2015. *Prognose von Zeitreihen: eine Einführung für Wirtschaftswissenschaftler*. Springer Gabler.
- Khintchine, A. 1934. Korrelationstheorie der stationären stochastischen Prozesse. *Mathematische Annalen* 109 (1): 604–615. ISSN: 0025-5831.
- Kinney, William R. 1978. ARIMA and Regression in Analytical Review: An Empirical Test. *The Accounting Review* 53 (1): 48–60. ISSN: 00014826.
- Koopmans, L. H. 1974. *The Spectral analysis of time series*. Academic Press.
- Kriesel, David. 1991. Ein kleiner Überblick über Neuronale Netze. *Physik in unserer Zeit* 22 (6): 255–259. ISSN: 00319252.
- Kruse, Rudolf, Christian Borgelt und Frank Klawonn. 2011. *Computational Intelligence: Eine methodische Einführung in Künstliche Neuronale Netze, Evolutionäre Algorithmen, Fuzzy-Systeme und Bayes-Netze*. Springer.
- Kunoth, Angela, u. a. 2018. *Splines and PDEs: from approximation theory to numerical linear algebra: Cetraro, Italy 2017*. Springer.
- Kwiatkowski, Denis, u. a. 1992. Testing the null hypothesis of stationarity against the alternative of a unit root: How sure are we that economic time series have a unit root? *Journal of Econometrics* 54 (1): 159–178. ISSN: 0304-4076.
- Lang, Christian B., und Norbert Pucker. 2016. *Mathematische Methoden in der Physik*. Springer Berlin.

- Langbein, Sven, und Alexander Czechowicz. 2013. *Konstruktionspraxis Formgedächtnistechnik Potentiale - Auslegung - Beispiele*. Springer Fachmedien Wiesbaden GmbH.
- Levendis, John D. 2018. *Time Series Econometrics: Learning Through Replication*. Springer International Publishing.
- Leybourne, S. J., und B. P. M. McCabe. 1994. A Consistent Test for a Unit Root. *Journal of Business & Economic Statistics* 12 (2): 157–166.
- Li, B., u. a. 2000. Neural-network-based motor rolling bearing fault diagnosis. *IEEE Transactions on Industrial Electronics* 47, Nr. 5 (): 1060–1069. ISSN: 0278-0046.
- Manson, S. S. 1953. *Behavior of materials under conditions of thermal stress*. National Advisory Committee for Aeronautics.
- Marks, Robert J. 2009. *Handbook of Fourier analysis and its applications*. Oxford University Press.
- Miner, M. A. 1945. Cumulative damage in fatigue. *Journal of Applied Mechanics* 12:149–164.
- numpy, FFT Dokumentation*. 2019. Abgerufen am: 2019-06-19. <https://docs.scipy.org/doc/numpy/reference/generated/numpy.fft.fft.html#numpy.fft.fft>.
- Papula, Lothar. 2015. *Mathematik für Ingenieure und Naturwissenschaftler: ein Lehr- und Arbeitsbuch für das Grundstudium. Band 2: Mit 345 Abbildungen, 300 Beispielen aus Naturwissenschaft und Technik sowie 324 Übungsaufgaben mit ausführlichen Lösungen*. 14., übera. Lehrbuch. Wiesbaden: Springer Vieweg. ISBN: 978-3-658-07790-7.
- . 2014. *Mathematische Formelsammlung: für Ingenieure und Naturwissenschaftler; mit zahlreichen Rechenbeispielen und einer ausführlichen Integraltafel*. 11., übera. Wiesbaden: Springer Vieweg. ISBN: 978-3-8348-1913-0 978-3-8348-2311-3.
- Paris, Paul C., Mario P. Gomez und William E. Anderson. 1961. A rational analytic theory of fatigue. *The Trend in Engineering* 13 (1): 9–14.
- Pearson, R. K. 1999. Data cleaning for dynamic modeling and control. In *1999 European Control Conference (ECC)*, 2584–2589. IEEE.
- Priestley, M. B., und T. Subba Rao. 1969. A Test for Non-Stationarity of Time-Series. *Journal of the Royal Statistical Society. Series B (Methodological)* 31 (1): 140–149. ISSN: 00359246.
- Rey, Günter Daniel, und Karl F. Wender. 2018. *Neuronale Netze: eine Einführung in die Grundlagen, Anwendungen und Datenauswertung*. 3., überarbeitete Auflage. Bern: Hogrefe. ISBN: 978-3-456-85796-1; 3-456-85796-9.

- Rinne, Horst. 2008. *Taschenbuch der Statistik*. Verlag Harri Deutsch.
- Ritz, Christian. 2009. *Nonlinear regression with R*. Springer.
- Rüschendorf, Ludger. 2014. Einführung: Datenanalyse und mathematische Statistik. *Mathematische Statistik*: 1–16.
- Schwenk, Holger, und Yoshua Bengio. 1997. AdaBoosting neural networks: Application to on-line character recognition. In *Artificial Neural Networks — ICANN'97*, 967–972. Berlin, Heidelberg: Springer Berlin Heidelberg. ISBN: 978-3-540-69620-9.
- Shazam Entertainment Limited. 2019. Abgerufen am 18.07.2019. <https://www.shazam.com/company>.
- Srivastava, Nitish, u. a. 2014. Dropout: A Simple Way to Prevent Neural Networks from Overfitting. *J. Mach. Learn. Res.* 15 (1): 1929–1958. ISSN: 1532-4435.
- Tang, Zaiyong, Chrys De Almeida und Paul A. Fishwick. 1991. Time series forecasting using neural networks vs. Box- Jenkins methodology. *Simulation* 57 (5): 303–310.
- Taylor, Sean J, und Benjamin Letham. 2017. *Forecasting at scale*.
- TensorFlow Core r1.14. Abgerufen am: 2019-06-19. https://www.tensorflow.org/api_docs/python/tf/keras/layers/TimeDistributed.
- Urban, Dieter, und Jochen Mayerl. 2018. *Angewandte Regressionsanalyse: Theorie, Technik und Praxis*. Springer VS.
- Vachtsevanos, G., und P. Wang. 2001. Fault prognosis using dynamic wavelet neural networks. In *2001 IEEE Autotestcon Proceedings. IEEE Systems Readiness Technology Conference. (Cat. No.01CH37237)*, 857–870.
- Wald, A., und J. Wolfowitz. 1940. On a Test Whether Two Samples are from the Same Population. *The Annals of Mathematical Statistics* 11 (2): 147–162. ISSN: 00034851.
- Wang, Avery Li-chun. 2003. An industrial-strength audio search algorithm. In *Proceedings of the 4 th International Conference on Music Information Retrieval*.
- Werbos, Paul, und Paul J. Paul John. 1974. *Beyond regression : new tools for prediction and analysis in the behavioral sciences*.
- Wilkes, Kenneth E., Peter K. Liaw und Kenneth E. Wilkes. 2000. The fatigue behavior of shape-memory alloys. *Jom* 52 (10): 45–51.
- Wu, Wing H., und L. McD. Schetky. 2000. „International Conference on Shape Memory and SuperelasticTechnolgies“. In *Proceedings of the International Conference on Shape Memory and SuperelasticTechnolgies*, 171–182.

Zhang, Huan, u. a. 2018. „Efficient Neural Network Robustness Certification with General Activation Functions“. In *Advances in Neural Information Processing Systems 31*, hrsg. von S. Bengio u. a., 4939–4948. Curran Associates, Inc.